

UNIVERSIDAD POLITÉCNICA DE MADRID
ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA DE SISTEMAS
INFORMÁTICOS



**Reorganización semántica no supervisada de
prospectos farmacéuticos mediante modelos de
lenguaje**

Proyecto Fin de Grado

Grado en Ciencia de Datos e Inteligencia Artificial

Curso académico 2025-2026

Autor:
Julia Sáenz de Dios

Tutor:
Carlos Badenes-Olmedo

Resumen

Este proyecto aborda el problema de la accesibilidad de la información en los prospectos de medicamentos. Tradicionalmente, estos documentos siguen una estructura legal y burocrática, utilizando un lenguaje técnico que dificulta que los pacientes encuentren de forma rápida y clara la información que necesitan. El objetivo principal de este trabajo es proponer una nueva forma de organizar estos contenidos, sustituyendo las secciones estándar por un índice dinámico basado en preguntas directas orientadas al usuario, sin modificar el contenido clínico original. Para ello, se ha diseñado un sistema capaz de analizar los textos de los prospectos y reorganizar su información de manera más comprensible. A partir de fuentes oficiales, el sistema identifica y agrupa los distintos fragmentos de información, asegurando que todo el contenido relevante se mantiene. Posteriormente, se generan preguntas representativas destinadas a resumir dichos bloques de información desde la perspectiva del paciente. Finalmente, estas preguntas se revisan y reorganizan para eliminar redundancias y mejorar su coherencia, dando lugar a un catálogo claro y estructurado. La evaluación del sistema se ha realizado comparando el nuevo índice de preguntas con la estructura tradicional de los prospectos. Los resultados muestran que esta nueva organización se ajusta mejor al contenido real y facilita el acceso a la información, especialmente en los apartados más relevantes para la salud. En conclusión, la reorganización de los prospectos en forma de preguntas constituye una solución eficaz para mejorar su comprensión y acercar la información farmacéutica a las necesidades reales de los pacientes.

Palabras clave: Procesamiento del lenguaje natural, Grandes modelos de lenguaje, Aprendizaje no supervisado, Indexación semántica, Similitud del coseno, Prospectos médicos.

Abstract

This project addresses the problem of information accessibility in medication leaflets. Traditionally, these documents follow a legal and bureaucratic structure, using technical language that makes it difficult for patients to quickly and clearly find the information they need. The main objective of the work is to propose a new way of organizing these contents, replacing standard sections with a dynamic index based on direct user-oriented questions, without modifying the original clinical content.

To this end, a system has been designed capable of analyzing the leaflet texts and reorganizing their information in a more understandable way. Based on official sources, the system identifies and groups the different fragments of information, ensuring that all relevant content is maintained. Subsequently, representative questions are generated that summarize these blocks of information from the patient's perspective. Finally, these questions are reviewed and reorganized to eliminate redundancies and improve their coherence, resulting in a clear and structured catalog.

The evaluation of the system was carried out by comparing the new question index with the traditional structure of the leaflets. The results show that this new organization better adjusts to the actual content and facilitates access to information, especially in the sections most relevant to health. In conclusion, the reorganization of leaflets in the form of questions constitutes an effective solution to improve their understanding and bring pharmaceutical information closer to the real needs of patients.

Keywords: Natural language processing, Large language models, Unsupervised learning, Semantic indexing, Cosine similarity, Patient information leaflets.

Índice

Resumen	I
Abstract	II
1. Introducción	1
1.1. Contexto	1
1.2. Motivación	1
1.3. Objetivos	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.4. Estructura del documento	2
2. Estado del arte	4
2.1. Alfabetización sanitaria y marcos de accesibilidad cognitiva	4
2.2. Representación vectorial y descubrimiento autónomo de dominios	6
2.3. Modelos de lenguaje de gran escala y síntesis generativa	8
2.4. Estado actual de la digitalización de prospectos	10
3. Metodología	13
3.1. Recolección de Prospectos y Estrategia de Muestreo	13
3.2. Preprocesamiento, Segmentación y Anonimización	14
3.2.1. Anonimización y Prevención de Sesgos Léxicos	15
3.2.2. Redundancia Estructural y Deduplicación Semántica	15
3.3. Vectorización Semántica en el Espacio Latente	16
3.3.1. Selección de Arquitecturas y Modelos de <i>Embeddings</i>	17
3.4. Clustering y Optimización Topológica	18
3.4.1. Selección del Número Óptimo de Clústeres	19
3.4.2. Partición Semántica Inicial ($K = 11$)	20
3.4.3. Configuración de 13 Clústeres	21
3.4.4. Configuración de 15 Clústeres	21
3.4.5. Configuración de 14 Clústeres	22
3.4.6. Configuración de 12 Clústeres	22
3.5. Síntesis Generativa de Preguntas Maestras	22
3.6. Refinamiento y Estandarización Final	29
3.6.1. Experimento de Segmentación Sintáctica	29
3.6.2. Análisis de Ruido	31
3.6.3. Estandarización final	32
4. Evaluación	35
4.1. Técnicas de Evaluación utilizadas	35
4.1.1. Representación Vectorial del Texto	35
4.1.2. Métrica de Similitud del Coseno	36
4.2. Evaluaciones	36
4.2.1. Evaluación Basada en Centroides Semántico	36
4.2.2. Evaluación Mediante Similitud Promedio Intra-Clúster	37
4.2.3. Estudio de Ablación Lingüística	37
4.2.4. Evaluación Comparativa frente a la Taxonomía Oficial	38
5. Resultados	41
5.1. Resultados de Validación Semántica	41
5.1.1. Similitud respecto al centroide	41
5.1.2. Similitud Promedio Intra-Clúster	42

5.2. Resultados del Estudio de Ablación Lingüística	43
5.3. Resultados del análisis de ruido	43
5.4. Resultados del Torneo Semántico	44
5.5. Resultados de Evaluación sobre Prospectos Reales	45
5.6. Objetivos Logrados	50
5.6.1. Objetivos específicos	50
5.6.2. Objetivo general	51
5.7. Discusión de Limitaciones y Problemas Encontrados	51
6. Conclusiones y trabajos futuros	54
6.1. Conclusiones	54
6.2. Impacto social y medioambiental	55
6.3. Líneas futuras	56
Bibliografía	57

Índice de tablas

3.1. Ejemplos de agrupaciones semánticas generadas mediante K-Means sobre embeddings densos ($K = 11$).	21
3.2. Resultados de la Síntesis Generativa: Comité Pentapartito ($K = 12$)	28
3.3. Similitud media al centroide por Clúster	32
5.1. Resultados de la Evaluación Multiterapéutica	48
5.2. Resultados Consolidados de la Macro-Evaluación ($N = 500$)	49
5.3. Tasa de Victoria (<i>Win-Rate</i>) por Sección Oficial	50

Índice de figuras

2.1. Diferencia entre K-Means y DBSCAN.	7
2.2. Arquitectura de embeddings Matryoshka.	7
2.3. Proceso de fragmentación, recuperación semántica y generación en arquitecturas RAG.	11
3.1. Curvas de Precision-Recall y F1-Score en el análisis manual.	17
3.2. Evolución de las métricas de Perplejidad, Inercia y Coeficiente de Silueta durante la búsqueda del número óptimo de clústeres.	20
3.3. Mapa Semántico de Tópicos: Unificación de grupos y detección de ruido mediante DBSCAN.	31
5.1. Comparativa de la similitud coseno de cada pregunta al centroide de su clúster.	41
5.2. Comparativa de la similitud coseno de cada pregunta a cada párrafo/frase de su clúster.	42
5.3. Comparativa entre preguntas completas y preguntas reducidas únicamente al núcleo semántico.	44
5.4. Distribución KDE de similitud semántica entre las Secciones Regulatorias y las Preguntas Maestras.	46
5.5. Comparativa de representatividad media por medicamento.	48
5.6. Distribución de la mejora porcentual en la muestra masiva de 500 prospectos.	49
6.1. ODS relacionados con este PFG.	55

Abreviaturas y Acrónimos

PIL	Patient Information Leaflet
ePIL	Electronic Patient Information Leaflet
E2R	Easy to Read
AEMPS	Agencia Española de Medicamentos y Productos Sanitarios
API	Application Programming Interface
CIMA	Centro de Información online de Medicamentos de la AEMPS
TF-IDF	Term Frequency – Inverse Document Frequency
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
IA	Inteligencia Artificial
Q&A	Question And Answer
LLMs	Large Language Models - Grandes modelos de lenguaje
PLN	Procesamiento del Lenguaje Natural
ODS	Objetivos de Desarrollo Sostenible

Capítulo 1

Introducción

1.1. Contexto

Cuando un paciente compra un medicamento, el acceso a la información de cómo tomarlo y qué precauciones debe tener es muy importante para su seguridad. En España, la Agencia Española de Medicamentos y Productos Sanitarios (AEMPS) garantiza que todos los fármacos incluyan un prospecto oficial, también accesible de forma online a través de la base de datos del Centro de Información de Medicamentos de la AEMPS (CIMA [1]). Sin embargo, existe una barrera de comunicación entre estos documentos y los pacientes, ya que suelen estar redactados con un lenguaje demasiado técnico, llenos de jerga médica y secciones largas que agrupan contenido muy diverso. Como resultado, buscar una duda rápida, como la dosis que debe tomar, y entenderla resulta una tarea difícil y, en muchas ocasiones, abrumadora para el ciudadano medio.

Por otro lado, vivimos en un momento de gran avance tecnológico. Más concretamente, el Procesamiento de Lenguaje Natural (PLN) y los Grandes Modelos de Lenguaje (LLMs, por sus siglas en inglés) han demostrado tener una muy buena capacidad para leer, estructurar y resumir textos complejos en cuestión de segundos.

A pesar de este avance, aplicar modelos de lenguaje directamente sobre documentos médicos oficiales presenta todavía un gran riesgo para la seguridad de los ciudadanos. Si simplemente se le pide a un LLM que resuma un prospecto, este podría equivocarse, omitir información crítica o incluso inventar datos, fallo conocido como “alucinación”. Por lo tanto, en la intersección entre la salud pública y las nuevas tecnologías, surge la necesidad de crear sistemas informáticos seguros que actúen como puente entre el paciente y la información médica. Para ello se deben diseñar arquitecturas que faciliten la accesibilidad, disminuyendo la complejidad de los prospectos. Una forma de conseguirlo es mediante un formato de preguntas y respuestas, donde las preguntas tengan un lenguaje cotidiano, garantizando en todo momento que la información original no pierda su rigor médico.

1.2. Motivación

La principal motivación de este proyecto nace de un problema real de salud pública que la sociedad vive en su día a día. Cuando una persona, normalmente preocupada o enferma, intenta leer un prospecto médico se enfrenta a un exceso de información que le provoca una alta carga cognitiva. Esto resulta en que muchas ocasiones el paciente se frustre, abandone la lectura, o ni la comience, dejando de prestar atención a detalles importantes para su salud. Esta desconexión entre la información existente y la que el paciente realmente logra comprender puede conducir a errores graves, como equivocarse con la dosis del fármaco o ignorar interacciones peligrosas con otros medicamentos. Por esta razón, la motivación humana de este proyecto es romper esa barrera y traducir la información sanitaria a un idioma accesible y universal que cualquiera pueda entender.

Desde el punto de vista técnico, la principal motivación es resolver el problema de la “caja negra” en los sistemas de lenguaje actuales. Hoy en día resulta muy sencillo crear un asistente virtual o un agente conversacional médico, pero estos sistemas son peligrosos porque, si no se controlan, pueden producir respuestas impredecibles o inventadas.

En cómputo general, el reto que se enfrenta en este trabajo es demostrar que se puede diseñar una

arquitectura predecible, segura y evaluable. En lugar de dejar que los grandes modelos de lenguaje generen texto libremente, se utilizarán herramientas matemáticas para orientar y limitar los modelos para que se ciñan al objetivo final. Así, se podrá construir una tecnología en la que un médico pueda confiar y un paciente pueda usar sin riesgo.

1.3. Objetivos

1.3.1. Objetivo general

El objetivo principal de este proyecto es diseñar, implementar y validar una arquitectura basada en Grandes Modelos de Lenguaje (LLMs) y otras técnicas matemáticas y computacionales, capaz de traducir automáticamente la complejidad técnica de los prospectos médicos oficiales a un catálogo universal de “Preguntas Maestras”, garantizando en todo momento el rigor clínico y mejorando la comprensión por parte del paciente.

1.3.2. Objetivos específicos

Para lograr este propósito general, el desarrollo del proyecto se divide en las siguientes metas técnicas:

- **O1. Automatización de la adquisición y normalización de datos:** Desarrollar un proceso de extracción de información oficial de la AEMPS que permita la posterior limpieza de la misma, garantizando un corpus de datos clínico depurado y procesable.
- **O2. Identificación y categorización de dominios informativos:** Organizar las frases médicas en “Macro-Tópicos” de forma automática, permitiendo que la propia información dicte la estructura del índice sin forzarla manualmente.
- **O3. Generación sintética de consultas orientadas al usuario:** Transformar la información de los prospectos en preguntas directas desde la perspectiva del paciente, asegurando la integridad del contenido clínico y la fidelidad a la fuente original.
- **O4. Establecimiento de un sistema de evaluación y selección objetiva:** Establecer un sistema de selección o descarte automática de preguntas que actúe de forma objetiva.
- **O5. Consolidación de un catálogo de referencia estándar:** Obtener las categorías universales que actúen como interfaz accesible y segura entre la documentación farmacológica y el usuario final.

1.4. Estructura del documento

Para facilitar la lectura y comprensión del proyecto, la presente memoria se ha estructurado de manera secuencial, reflejando el ciclo de vida real del desarrollo de la arquitectura y las decisiones técnicas tomadas. El documento se divide en los siguientes capítulos:

- **Capítulo 1. Introducción:** Define el contexto clínico y tecnológico, expone la problemática que motiva el proyecto y detalla los objetivos generales y específicos que se persiguen.
- **Capítulo 2. Estado del Arte:** Analiza el panorama tecnológico actual. Se revisa la evolución de los Modelos de Lenguaje de Gran Escala (LLMs), la fundamentación matemática de los espacios vectoriales (*embeddings*), el aprendizaje no supervisado y las soluciones actuales a la problemática.

- **Capítulo 3. Metodología y Arquitectura del Sistema:** Describe el proceso científico siguiendo el pipeline de desarrollo: recolección de prospectos, preprocesamiento de datos, vectorización, agrupamiento (*clustering*), generación de consultas y refinamiento. Se documentan de forma sistemática las decisiones de diseño y la lógica algorítmica empleada en cada fase del tratamiento de la información.
- **Capítulo 4. Evaluación:** Establece los criterios y métricas para auditar el rendimiento del sistema. Se justifica el uso de indicadores de proximidad semántica y cohesión para validar la estructura del nuevo índice, sentando las bases teóricas antes del análisis de los resultados.
- **Capítulo 5. Resultados y Discusión:** Presenta el catálogo final de categorías universales y analiza el rendimiento observado frente a la estructura convencional de los prospectos. Incluye una discusión crítica sobre las limitaciones identificadas y su impacto en el sistema.
- **Capítulo 6. Conclusiones y Trabajo Futuro:** Sintetiza los hallazgos del proyecto, evalúa el grado de cumplimiento de los objetivos planteados y propone nuevas líneas de investigación, como la integración de esta arquitectura en sistemas de Generación Aumentada por Recuperación (RAG) para entornos asistenciales.

Capítulo 2

Estado del arte

2.1. Alfabetización sanitaria y marcos de accesibilidad cognitiva

El hecho de que un paciente tenga acceso al prospecto oficial de un medicamento no implica necesariamente que pueda comprenderlo de forma adecuada. Diversos trabajos han señalado una desconexión persistente entre la complejidad lingüística de los Prospectos de Información al Paciente (PIL, por sus siglas en inglés) y el nivel de alfabetización sanitaria de una parte importante de la población [2]. Como se ha mencionado en anteriores secciones, esta diferencia no constituye únicamente un problema comunicativo, en contextos clínicos reales, puede traducirse en errores de medicación, interpretaciones incorrectas de dosis o una menor adherencia terapéutica.

Tradicionalmente, los documentos regulatorios han priorizado la precisión técnica frente a la accesibilidad del contenido. Como consecuencia, es habitual encontrar terminología altamente especializada, estructuras de voz pasiva y oraciones extensas cuya interpretación requiere un nivel de comprensión lectora relativamente elevado [3, 4, 5]. Algunos estudios cualitativos muestran, incluso, que determinados pacientes perciben los prospectos como textos escritos en una especie de "*lenguaje médico en latín*", alejados de la forma en que las personas interpretan la información [6].

En respuesta a este problema, durante los últimos años han ganado relevancia enfoques como la **Lectura Fácil** (*Easy-to-Read*, **E2R**) y el **Lenguaje Llano** (*Plain Language*). Aunque ambos comparten el objetivo de mejorar la comprensión, no persiguen exactamente las mismas prioridades metodológicas.

La **Lectura Fácil** (**E2R**) surge principalmente en contextos de accesibilidad cognitiva y está orientada a personas con dificultades de comprensión lectora, incluyendo personas con discapacidad intelectual, bajo nivel educativo o hablantes no nativos. Suelen insistir en el uso de frases breves, vocabulario frecuente, estructuras sintácticas simples y una organización visual explícita del contenido. Además, uno de los aspectos más relevantes de este enfoque es que incorpora procesos de validación con usuarios reales, ya que una simplificación lingüística teórica no siempre garantiza que el mensaje resulte verdaderamente comprensible en la práctica.

Por otro lado, el **Lenguaje Llano** se centra más en la eficiencia comunicativa para población general que en la accesibilidad cognitiva estricta. Su propósito no consiste únicamente en "simplificar" el texto, sino en reducir ambigüedades innecesarias y facilitar que el lector encuentre y utilice la información con rapidez. Para ello, suele priorizar estructuras en voz activa, una organización jerárquica clara y la sustitución de terminología excesivamente técnica por expresiones de uso común cuando el contexto lo permite.

No obstante, la aplicación de estos enfoques en documentación farmacológica plantea ciertas tensiones. Una simplificación excesiva puede comprometer matices clínicos relevantes, especialmente en secciones relacionadas con contraindicaciones, efectos adversos o instrucciones de administración. Por ello, varios autores insisten en que la accesibilidad no debería entenderse como una reducción indiscriminada de contenido, sino como un proceso de reorganización y adaptación lingüística que preserve la precisión clínica original.

En este contexto, distintos trabajos proponen abandonar parcialmente el modelo tradicional de narrativa lineal para adoptar estructuras modulares basadas en el formato de **Preguntas y Respuestas** (**Q&A**). Este planteamiento suele apoyarse en principios derivados de la "Teoría de la Carga Cognitiva"

[7], según la cual la memoria de trabajo humana posee una capacidad limitada para procesar información nueva de manera simultánea. Desde esta perspectiva, el problema de los prospectos no reside únicamente en el contenido clínico en sí mismo, sino también en la forma en que dicho contenido se distribuye y presenta al lector.

En la Teoría de la Carga Cognitiva suele distinguirse entre tres tipos de carga:

- **Carga Intrínseca:** Hace referencia a la dificultad inherente del propio contenido médico, como puede ocurrir con la explicación del mecanismo de un fármaco o determinadas advertencias farmacológicas. Esta carga depende de la complejidad conceptual del tema y, en gran medida, no puede eliminarse sin comprometer la fidelidad científica de la información. En otras palabras, ciertos aspectos clínicos seguirán siendo difíciles incluso aunque el texto esté correctamente redactado.
- **Carga Extrínseca:** Corresponde al esfuerzo mental adicional generado por un diseño comunicativo deficiente. Prospectos extensos, ausencia de jerarquías visuales claras o estructuras sintácticas excesivamente densas obligan al paciente a dedicar recursos cognitivos a descifrar el texto en lugar de comprender las instrucciones sanitarias relevantes.
- **Carga Relevante:** Representa el esfuerzo cognitivo útil, es decir, aquel que contribuye realmente a la construcción de esquemas mentales y a la consolidación de la información en memoria a largo plazo.

A partir de estas ideas, algunos autores defienden que los formatos Q&A pueden reducir parte de la carga extrínseca al fragmentar la información en unidades más manejables. Este proceso, habitualmente relacionado con la técnica de *chunking*, facilita que el lector localice rápidamente respuestas concretas mediante un escaneo visual del documento [8]. No obstante, aunque varios estudios reportan mejoras en comprensión y retención de información frente a los formatos regulatorios convencionales [9], todavía existe cierto debate sobre hasta qué punto estas estructuras son igualmente eficaces para todos los perfiles de pacientes. En personas con bajo conocimiento sanitario, por ejemplo, la fragmentación excesiva puede dificultar la comprensión global del tratamiento si las relaciones entre conceptos quedan demasiado dispersas.

En paralelo, la automatización de estas tareas de adaptación lingüística ha comenzado a apoyarse en **Modelos de Lenguaje de Gran Escala (LLMs)**. A diferencia de los sistemas simbólicos tradicionales, que dependían de reglas rígidas y diccionarios cerrados, los LLMs permiten una reformulación más flexible del contenido médico en función del contexto. Entre las capacidades más relevantes descritas en la literatura destacan la sustitución contextual de terminología técnica por expresiones más frecuentes, la simplificación de estructuras sintácticas complejas y la adaptación del nivel de lectura mediante aprendizaje en contexto (*In-Context Learning*) [10, 11].

Sin embargo, el uso de estos modelos en documentación clínica continúa siendo un área metodológicamente sensible. Aunque los resultados en legibilidad suelen ser prometedores, una mejora lingüística no garantiza necesariamente una mejor comprensión médica. Como ya se ha mencionado, algunos trabajos recientes señalan que ciertos modelos tienden a resumir en exceso información crítica o a modificar relaciones semánticas sutiles durante el proceso de simplificación, especialmente cuando las instrucciones del sistema priorizan la fluidez frente a precisión regulatoria.

Para evaluar de forma objetiva el impacto de estas transformaciones, la literatura suele emplear métricas de legibilidad como el índice **Flesch Reading Ease (FRE)**, que estima la dificultad de un texto a partir de la longitud media de las oraciones y de la densidad silábica de las palabras:

$$FRE = 206,835 - 1,015 \left(\frac{\text{Palabras Totales}}{\text{Oraciones Totales}} \right) - 84,6 \left(\frac{\text{Sílabas Totales}}{\text{Palabras Totales}} \right) \quad (2.1)$$

En términos generales, valores más altos del índice suelen asociarse con textos más fáciles de leer. Algunos estudios recientes muestran incrementos sustanciales de más de 30 puntos en la escala

de legibilidad tras aplicar sistemas generativos sobre textos médicos orientados al público [12]. Aun así, estas métricas presentan limitaciones importantes ya que evalúan propiedades superficiales del lenguaje, pero no pueden determinar si el paciente ha comprendido correctamente implicaciones clínicas complejas o se ha omitido información importante.

2.2. Representación vectorial y descubrimiento autónomo de dominios

La idea de transformar un prospecto tradicional en un sistema de preguntas y respuestas no es solo un problema de “reformato” del texto. En realidad, conlleva la decisión de qué significa realmente organizar información clínica de manera útil para un paciente sin distorsionar lo que el documento regulatorio intenta proteger. En ese sentido, la etapa de identificación de temas o dominios es una interpretación del propio contenido.

Durante años, este tipo de análisis se apoyó en modelos estadísticos clásicos como *Latent Dirichlet Allocation (LDA)* [13]. Su lógica es elegante, pero también bastante limitada cuando se baja al terreno clínico real. LDA depende en exceso de la co-ocurrencia de palabras, lo que en textos médicos cortos puede ser un problema serio ya que no siempre hay suficiente contexto para inferir significado estable. Esto lleva a situaciones poco satisfactorias, como no poder relacionar “cefalea” y “dolor de cabeza” si el texto no las conecta explícitamente. En la práctica, este tipo de limitación hace que el modelo sea menos útil justo donde más se necesita precisión semántica.

Por eso, el campo se ha ido desplazando hacia representaciones vectoriales densas y técnicas de agrupamiento más flexibles. Aun así, no está del todo claro que esto sea una mejora “sin coste”. Algoritmos como *K-Means* [14], aunque siguen siendo muy utilizados por su simplicidad, imponen supuestos bastante fuertes: obligan a fijar el número de grupos de antemano y asumen una geometría de clústeres que rara vez se cumple, sobre todo en datos clínicos reales. Esto puede funcionar en escenarios controlados, pero en textos regulatorios, donde conviven descripciones farmacológicas y administrativas, esa rigidez empieza a ser un problema más que una ventaja.

En contraste, métodos basados en densidad como *DBSCAN* [15] ofrecen una alternativa más flexible. No obligan a decidir de antemano cuántos grupos existen y permiten que ciertas partes del texto queden fuera del agrupamiento clasificadas como ruido. Esto, en teoría, es una ventaja clara. Sin embargo, también introduce otra dificultad, la dependencia de hiperparámetros como ϵ o MinPts puede hacer que los resultados varíen bastante según el dominio o incluso según cómo esté redactado el documento. En otras palabras, se gana flexibilidad, pero se pierde estabilidad. Y esa tensión no siempre está resuelta en la práctica.

Aun con estas limitaciones, la calidad de cualquier método de agrupamiento depende en gran medida de cómo se representen los textos. Aquí entran los *embeddings*, que en teoría permiten proyectar el lenguaje a un espacio donde la distancia geométrica refleja similitud semántica. Esta idea es potente, pero también algo idealizada ya que no siempre es evidente que la “distancia” en ese espacio capture bien diferencias clínicas relevantes, especialmente en casos ambiguos o con terminología cercana.

Los enfoques actuales suelen apoyarse en aprendizaje contrastivo, con funciones como *InfoNCE*, que empujan al modelo a acercar frases semánticamente equivalentes y a alejar las que no lo son. Aunque este mecanismo ha mostrado buenos resultados, también introduce una dependencia fuerte de los datos negativos seleccionados durante el entrenamiento. Si esos ejemplos no están bien contruidos, el espacio vectorial puede quedar sesgado de formas difíciles de detectar.

Dentro de este panorama, se han propuesto distintas arquitecturas con ventajas y compromisos distintos:

- **Modelos Multilingües Ligeros:** como MiniLM o MPNet [16], que funcionan bien en escenarios prácticos por su eficiencia, aunque a veces sacrifican matices semánticos finos en favor de velocidad




Figura 2.1: Diferencia entre K-Means y DBSCAN.

y escalabilidad.

- **Arquitecturas *Mixture of Experts* (MoE):** como *Nomic Embed*, que intentan especializar partes del modelo mediante mecanismos de enrutamiento. En teoría esto mejora la eficiencia, pero en la práctica puede introducir comportamientos difíciles de interpretar, ya que no siempre es claro qué “experto” está influyendo en cada decisión [17].
- **Representaciones *Matryoshka*:** como *Matryoshka Representation Learning* [18] (Figura 2.2), que permiten truncar vectores manteniendo parte de la información semántica. Es una idea atractiva desde el punto de vista computacional, aunque todavía no está del todo claro hasta qué punto esa compresión es estable en dominios clínicos complejos.




Figura 2.2: Arquitectura de embeddings Matryoshka.

La evaluación de estos sistemas también es un punto delicado. Métricas clásicas como BLEU o ROUGE [19] se han utilizado durante años, pero su dependencia de coincidencias superficiales

de palabras puede ser problemática en contextos médicos, donde dos expresiones distintas pueden ser igualmente válidas clínicamente. Esto hace que, en algunos casos, penalicen precisamente lo que deberían aceptar.

Por eso se ha ido imponiendo la Similitud Textual Semántica (STS), basada en medidas como la similitud del coseno, que permite comparar fragmentos de texto atendiendo principalmente a su proximidad semántica y no únicamente a coincidencias léxicas superficiales:

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} \quad (2.2)$$

Este enfoque resulta especialmente útil en entornos clínicos, donde distintas expresiones pueden transmitir una misma idea médica sin compartir exactamente la misma estructura sintáctica. En comparación con métricas tradicionales basadas en n-gramas, STS ofrece una evaluación más flexible y más cercana al comportamiento real de los modelos semánticos modernos.

De forma complementaria, las métricas **Top-k** permiten cuantificar hasta qué punto el sistema es capaz de recuperar las secciones más relevantes del documento original ante una consulta determinada. Estas métricas son especialmente valiosas en arquitecturas basadas en recuperación semántica, ya que proporcionan una forma reproducible de evaluar la fidelidad entre las preguntas generadas y “Gold Standard”.

Aunque ninguna métrica aislada puede capturar por completo la complejidad de la comprensión humana, la combinación de STS y Top-k proporciona un marco de evaluación razonablemente sólido para analizar tanto la representatividad semántica como la precisión de recuperación del sistema. En este contexto, más que sustituir la validación humana, estas métricas permiten establecer criterios cuantitativos sobre los que comparar distintas configuraciones y estrategias de procesamiento.

2.3. Modelos de lenguaje de gran escala y síntesis generativa

Una vez identificados los dominios temáticos del prospecto, aparece un problema más complejo que la simple clasificación del contenido y es cómo transformar información regulatoria altamente técnica en preguntas y respuestas comprensibles sin alterar el significado original. En teoría, los Modelos de Lenguaje de Gran Escala (LLMs) ofrecen una solución atractiva para esta tarea, ya que su capacidad de síntesis permite reorganizar y reformular texto con un nivel de fluidez difícil de alcanzar mediante sistemas tradicionales. Algunos trabajos recientes incluso sugieren que, en determinados escenarios, los resultados pueden aproximarse a la calidad de simplificaciones de contenido clínico realizadas por expertos humanos [20].

Sin embargo, estas comparaciones deben interpretarse con cierta cautela. Que un modelo genere un texto fluido y aparentemente claro no implica necesariamente que conserve todos los matices del documento original. Y ahí aparece una de las principales dificultades de aplicar LLMs a prospectos farmacológicos, mejorar la accesibilidad sin alterar información que, aunque resulte densa o difícil de leer, tiene implicaciones de seguridad importantes.

En este tipo de documentos, pequeños cambios de redacción pueden modificar el alcance de una advertencia, suavizar una contraindicación o simplificar en exceso instrucciones que necesitan cierto grado de precisión. Por eso, la adaptación automática del lenguaje no siempre es un proceso trivial. A veces, lo que mejora la legibilidad también puede reducir especificidad o introducir ambigüedades no deseadas.

A esto se añade otra limitación importante, los LLMs siguen siendo modelos probabilísticos. No interpretan el texto como lo haría un especialista, sino que generan secuencias de palabras (tokens) a partir de patrones aprendidos durante el entrenamiento. En la práctica, esto puede traducirse en respuestas redundantes, excesivamente genéricas o incluso incorrectas, sobre todo cuando el sistema

prioriza naturalidad conversacional frente a exactitud técnica.

Para reducir parcialmente esta variabilidad, la literatura reciente ha dado una importancia creciente al **Prompt Engineering** [21]. Aunque en muchos contextos se presenta casi como una solución universal, en realidad funciona más como un mecanismo de control aproximado que como una garantía absoluta de comportamiento. El diseño de instrucciones permite orientar la inferencia del modelo hacia determinados estilos de respuesta, niveles de complejidad lingüística o restricciones sintácticas, alterando las probabilidades de generación de ciertos términos y estructuras.

En el contexto farmacológico, este proceso suele relacionarse con el concepto de **alineamiento** (*Alignment*). Más que convertir el modelo en un “experto médico”, el alineamiento intenta reducir comportamientos indeseados y aproximar las respuestas generadas a criterios humanos de claridad, seguridad y fidelidad clínica. Aun así, el grado real de control que se obtiene continúa siendo discutido. Incluso modelos altamente alineados pueden generar respuestas inconsistentes ante pequeñas variaciones del contexto o de la formulación del *prompt*.

Técnicas como el *Role-Prompting* o el *Few-Shot Prompting* suelen utilizarse precisamente para estabilizar parte de ese comportamiento. Introducir ejemplos previos o asignar un rol específico al modelo puede mejorar la coherencia estilística y favorecer estructuras más cercanas al lenguaje llano. Sin embargo, tampoco está completamente claro hasta qué punto estas estrategias producen una comprensión “real” del contexto clínico o simplemente inducen patrones superficiales de redacción. En muchos casos, el modelo aprende a sonar accesible sin que exista necesariamente una garantía sobre la conservación exacta del significado médico original.

Uno de los problemas más delicados sigue siendo el fenómeno de las **alucinaciones** [22]. En modelos generativos, una respuesta puede resultar coherente desde el punto de vista lingüístico y, aun así, contener información clínicamente errónea o inexistente. Este riesgo adquiere especial relevancia en documentación farmacológica, donde errores aparentemente menores, por ejemplo, una simplificación incorrecta de una contraindicación o una alteración sutil en una pauta de administración, podrían tener consecuencias importantes para la seguridad del paciente.

Por esta razón, una parte de la investigación reciente se ha desplazado hacia arquitecturas colaborativas o de comité (*Ensemble Modeling*), donde varios modelos participan simultáneamente en el proceso de generación y validación. La idea detrás de estos enfoques no es tanto eliminar errores por completo, algo que sigue siendo poco realista, sino reducir la dependencia de un único modelo y aprovechar diferentes fortalezas arquitectónicas.

- **Modelos orientados al razonamiento:** sistemas como **DeepSeek-R1** [23], que incorporan estrategias de razonamiento paso a paso mediante aprendizaje por refuerzo y técnicas de *Chain of Thought*. Estos modelos suelen mostrar mejor desempeño en tareas deductivas complejas, aunque a costa de tiempos de inferencia mayores y, en ocasiones, respuestas excesivamente largas.
- **Modelos generalistas de gran escala:** familias como **Llama 3**, **Qwen**, **Gemma** o **Nemotron**, que destacan por su robustez lingüística y capacidad de seguimiento de instrucciones [24, 25, 26, 27]. A este ecosistema abierto se suman iniciativas orientadas a la transparencia y replicabilidad comunitaria, como los modelos de la serie **GPT-OSS** [28]. Aun así, incluso estos modelos presentan degradaciones semánticas en determinados idiomas o dominios especializados, especialmente cuando el vocabulario técnico es muy específico.

Finalmente, algunos trabajos recientes han comenzado a utilizar estrategias de **LLM-as-a-Judge**, donde un modelo adicional evalúa automáticamente las respuestas generadas por otros sistemas [29]. Este enfoque resulta interesante porque introduce una forma de validación cruzada relativamente escalable, aunque también plantea una paradoja ya que un modelo generativo pasa a supervisar a otro modelo generativo. En consecuencia, la calidad de la evaluación continúa dependiendo de criterios probabilísticos y no de una verificación clínica verdaderamente determinista.

A pesar de estas limitaciones, este tipo de arquitecturas sí parece ofrecer una mejora práctica respecto al uso aislado de un único modelo. Más que resolver completamente el problema de la fiabilidad,

los enfoques de comité permiten reducir parte de la variabilidad inherente a los LLMs y proporcionan un marco más robusto para tareas sensibles de reorganización y adaptación de información.

2.4. Estado actual de la digitalización de prospectos

En los últimos años, la digitalización de prospectos farmacológicos ha empezado a desplazarse desde modelos centrados únicamente en la accesibilidad documental hacia sistemas capaces de reorganizar la información según las necesidades concretas del usuario. Este cambio no responde solo a avances en procesamiento de lenguaje natural, sino también a una limitación práctica. Muchos pacientes disponen técnicamente de la información, pero no necesariamente consiguen localizar o interpretar aquello que necesitan en el momento adecuado.

En este contexto, los Modelos de Lenguaje de Gran Escala (LLMs) han comenzado a utilizarse no solo para simplificar vocabulario, sino también para reestructurar la navegación del contenido. La idea de fondo es relativamente sencilla, es adaptar la organización del prospecto a preguntas reales formuladas por pacientes en lugar de obligar al usuario a recorrer estructuras regulatorias extensas y, en ocasiones, poco intuitivas. Sin embargo, esta transición también introduce una tensión importante. Cuanto más se adapta el lenguaje a formatos conversacionales, mayor es el riesgo de perder parte de la precisión o de descontextualizar información relevante que originalmente estaba integrada dentro de una explicación más amplia.

La mayoría de los sistemas recientes se apoyan en arquitecturas de **Retrieval-Augmented Generation (RAG)** [30]. Aunque el término suele utilizarse de forma bastante amplia, en esencia describe una estrategia donde el modelo generativo no trabaja únicamente con conocimiento aprendido durante el entrenamiento, sino también con fragmentos recuperados dinámicamente desde un documento fuente.

Habitualmente, este proceso se organiza en tres etapas principales, representadas en la Figura 2.3:

■ Indexación y fragmentación semántica (*Indexing*):

El primer problema aparece por una limitación relativamente conocida de los LLMs, la dificultad para manejar documentos largos sin degradar progresivamente la atención sobre partes anteriores del texto. Para evitarlo, el prospecto se divide en fragmentos o *chunks*. Esta fragmentación no es una decisión trivial, ya que segmentar demasiado puede romper relaciones semánticas importantes, mientras que utilizar bloques excesivamente grandes reduce precisión durante la recuperación posterior.

Por ello, muchos sistemas introducen un cierto grado de solapamiento (*overlap*) entre fragmentos consecutivos. La intención es preservar contexto entre secciones próximas y evitar que información relevante quede artificialmente separada. Aun así, no existe un criterio universal sobre el tamaño óptimo de los fragmentos, y distintos trabajos muestran comportamientos bastante variables dependiendo de la estructura del documento.

Una vez dividido el texto, cada fragmento se transforma en una representación vectorial o *embedding*. En este contexto, un *embedding* puede entenderse como una proyección matemática del texto a un espacio numérico de alta dimensionalidad donde fragmentos con significado similar tienden a situarse próximos entre sí. Estos vectores se almacenan posteriormente en bases de datos vectoriales, permitiendo realizar búsquedas semánticas más allá de coincidencias exactas de palabras.

■ Recuperación condicionada por similitud (*Retrieval*):

Cuando el usuario formula una consulta, el sistema transforma también esa pregunta en un vector utilizando el mismo codificador semántico. Posteriormente, se calcula la proximidad entre la consulta y los fragmentos almacenados, normalmente mediante medidas como la similitud del coseno.

El objetivo de esta fase no consiste únicamente en recuperar texto “parecido”, sino en identificar qué partes del texto son realmente relevantes para la intención de la pregunta. Aquí aparece el concepto de **alineamiento semántico**, entendido como el grado de correspondencia entre la intención expresada por el usuario y el contenido recuperado por el sistema.

En la práctica, este proceso suele funcionar razonablemente bien para consultas directas, aunque también tiene limitaciones. Determinadas preguntas ambiguas o demasiado generales pueden recuperar fragmentos parcialmente relevantes o introducir redundancia entre resultados similares. Además, algunos apartados administrativos o regulatorios contienen terminología recurrente que puede sesgar la recuperación semántica aunque no aporten información útil para la consulta concreta.

Para controlar parcialmente este problema, algunos sistemas limitan el número de fragmentos recuperados mediante estrategias *Top-k*. En este contexto, k representa el número máximo de fragmentos seleccionados para construir la respuesta final. Elegir valores bajos puede mejorar precisión pero aumentar el riesgo de perder contexto; valores demasiado altos, en cambio, suelen introducir ruido semántico y fragmentos redundantes.

■ Síntesis y reescritura generativa (*Generation*):

En la etapa final, los fragmentos recuperados se incorporan al *prompt* utilizado por el modelo generativo. A partir de ahí, el LLM reorganiza la información en un formato más cercano a una interacción conversacional.

Este punto probablemente concentra la mayor parte de las ventajas y también de las dificultades metodológicas de las arquitecturas RAG. Por un lado, el sistema puede generar respuestas mucho más accesibles que el texto original del prospecto, reduciendo tecnicismos innecesarios y reorganizando la información de forma más intuitiva para el usuario. Por otro, cuanto mayor es la libertad generativa del modelo, mayor es también la posibilidad de introducir simplificaciones excesivas, omisiones o reinterpretaciones no deseadas.

Precisamente por eso, algunos trabajos recientes empiezan a cuestionar hasta qué punto resulta conveniente utilizar LLMs para redactar directamente respuestas farmacológicas completas. Aunque las respuestas suelen ser más naturales y fáciles de leer, la fluidez lingüística puede generar una falsa sensación de fiabilidad incluso cuando existen pequeñas desviaciones respecto al contenido original.




Figura 2.3: Proceso de fragmentación, recuperación semántica y generación en arquitecturas RAG.

A pesar de su potencial, la aplicación de arquitecturas RAG en este contexto sigue planteando dudas importantes. Buena parte de los sistemas actuales utilizan el modelo generativo no solo para organizar la información, sino también para redactar directamente las respuestas [31]. Esto introduce un problema difícil de ignorar y es que cuanto mayor es la intervención del modelo en la redacción, mayor es también la posibilidad de que se modifiquen matices relevantes o se omita información crítica.

En este contexto, el término **alucinación semántica** suele utilizarse para describir situaciones en las que el modelo genera información lingüísticamente coherente pero no respaldada explícitamente por el documento fuente. Aunque este fenómeno no siempre produce errores graves, sí introduce incertidumbre sobre el grado de fidelidad entre la respuesta generada y el contenido original del texto.

Por todo esto, todavía existe una brecha importante entre los enfoques centrados en accesibilidad y aquellos orientados a preservar fielmente el contenido del prospecto. Como se ha mencionado, buena

parte de los sistemas actuales utilizan modelos generativos tanto para recuperar información como para reformularla posteriormente en lenguaje natural. Aunque esta estrategia puede producir respuestas más fluidas y cercanas al usuario, también aumenta el riesgo de introducir simplificaciones excesivas, omisiones o cambios sutiles de significado.

Precisamente en esa tensión se sitúa este proyecto. La propuesta parte de una idea más conservadora, separar de forma explícita las tareas de recuperación y generación. En lugar de utilizar el LLM como un sistema encargado de reescribir completamente el contenido, el modelo actúa principalmente como mecanismo de organización semántica y navegación documental. Es decir, la inteligencia artificial se emplea para generar preguntas, construir índices dinámicos o facilitar el acceso contextual a la información, mientras que el contenido mostrado al usuario permanece vinculado directamente a los fragmentos originales recuperados desde el prospecto.

Esta separación de responsabilidades resulta relevante porque intenta mantener un equilibrio entre accesibilidad y fidelidad documental. El sistema sigue aprovechando la flexibilidad de los modelos generativos para reorganizar información y reducir barreras de comprensión, pero evita delegar completamente en el modelo la reformulación del contenido.

Capítulo 3

Metodología

3.1. Recolección de Prospectos y Estrategia de Muestreo

El desarrollo de cualquier sistema de Procesamiento de Lenguaje Natural depende en gran medida de la calidad y comprensión del conjunto de datos sobre el que se construye. En este trabajo, la fase inicial no se centró únicamente en recopilar prospectos médicos, sino en entender cómo estaban realmente estructurados, si se podía mejorar la organización, es decir, si dentro de cada sección había frases que no terminaban de encajar semánticamente, y comprobar si era compatible con las tareas posteriores de extracción semántica, agrupamiento y generación de preguntas.

La fuente de verdad (*Ground Truth*) para esta investigación son los Prospectos de Información al Paciente (PILs) publicados oficialmente en el Centro de Información online de Medicamentos de la AEMPS (CIMA [1]). Aunque estos documentos siguen una plantilla regulatoria relativamente estable, el análisis manual mostró que la organización de las secciones suele mantenerse, pero la densidad de información, el estilo de redacción y el nivel de detalle varían entre medicamentos, especialmente cuando se comparan formatos o grupos terapéuticos distintos.

Precisamente por esta variabilidad, utilizar un único conjunto de datos fijo durante todo el proyecto habría resultado problemático. Un sistema puede comportarse bien en un subconjunto concreto y, aun así, fallar cuando se enfrenta a prospectos con estructuras menos frecuentes o formulaciones distintas. Para evitar este tipo de sobreajuste, se optó por construir varios subconjuntos de datos adaptándolos según la fase de la investigación en la que se tratara:

- **Dataset Exploratorio (D_{exp}):** formado por 50 prospectos utilizados para realizar una auditoría manual inicial de la estructura documental y detectar patrones recurrentes, inconsistencias y limitaciones del proceso de extracción.
- **Dataset de Descubrimiento de Tópicos (D_{topic}):** compuesto por 2000 prospectos. Utilizado como entorno de pruebas para el descubrimiento de temas existentes en los prospectos médicos.
- **Dataset Base de Desarrollo (D_{base}):** compuesto por 500 prospectos. Utilizado como entorno de pruebas para el ajuste paramétrico de los algoritmos de *clustering* (K-Means) y la optimización de clústeres.
- **Dataset de Escalabilidad (D_{scale}):** un corpus ampliado de 1000 prospectos. Empleado para explorar y verificar que la diversidad y valor del dataset se mantenía estable ante un mayor volumen de datos.
- **Dataset de Evaluación Final (D_{eval}):** conjunto ciego (*hold-out dataset*) de 500 prospectos reservado exclusivamente para la evaluación final del sistema

La extracción automática de todos los datasets se implementó mediante una clase propia denominada *CimaFetcher*, desarrollada sobre la librería *BeautifulSoup*. Esta clase centralizó todo el proceso de recolección documental utilizando la API oficial de CIMA. El sistema inspeccionaba los prospectos de cada medicamento gracias al parámetro correspondiente al tipo de documento que proporciona la API, donde el tipo 2 correspondía al prospecto. Esta clase se adaptó según si se querían obtener prospectos específicos elegidos manualmente (el parámetro de entrada es una lista con los identificadores de los prospectos), o si se querían extraer de manera aleatoria y automática (el parámetro de entrada es el número de prospectos a extraer).

A partir de esta recolección se hacía una segmentación, en la que para todos los datasets se obtenía un dataframe donde cada línea era una frase. Sin embargo, una excepción fue para el D_{exp} , en el que cada documento se transformó en pares formados por un *título de sección* y su correspondiente fragmento textual. El corpus inicial generado contenía 5636 frases, que posteriormente fueron revisadas y anotadas manualmente para construir un *Gold Standard* de referencia.

3.2. Preprocesamiento, Segmentación y Anonimización

Una vez completada la fase de recolección documental, el siguiente problema no fue obtener más datos, sino conseguir que esos datos fueran realmente utilizables desde el punto de vista semántico. Aunque los prospectos comparten una estructura regulatoria relativamente homogénea, el contenido textual presenta numerosos problemas prácticos: fragmentos incompletos, listas separadas de su contexto, repeticiones administrativas y una fuerte dependencia de nombres comerciales.

En otras palabras, antes de aplicar modelos de *embeddings* o algoritmos de agrupamiento, era necesario intervenir sobre el propio texto. De lo contrario, el sistema terminaba sobreajustándose a características superficiales del documento en lugar de relaciones conceptuales útiles para el clustering semántico.

Además, esta fase puso de manifiesto una contradicción importante. En teoría, mantener el texto original intacto maximiza la fidelidad documental, sin embargo, en la práctica, conservar literalmente toda la estructura del prospecto introduce una gran cantidad de ruido redundante que distorsiona los modelos vectoriales. Simplificar demasiado el contenido podía hacer perder matices relevantes, pero no intervenir en absoluto provocaba agrupaciones artificiales y sesgos léxicos difíciles de controlar. Por ello, el preprocesamiento se planteó no como una limpieza agresiva, sino como un equilibrio entre conservación documental y estabilidad semántica.

Tras las primeras pruebas exploratorias y una vez validado que los algoritmos de distancia vectorial producían agrupaciones coherentes, se construyó el Dataset Base de Desarrollo (D_{base}), compuesto por 500 prospectos representativos.

Durante esta selección se aplicó un criterio de unicidad documental para evitar redundancias derivadas de distintas presentaciones comerciales de un mismo medicamento. Prospectos prácticamente idénticos, diferenciados únicamente por dosis o formato comercial, podían alterar artificialmente la distribución estadística del corpus. Por ejemplo, variantes como “Ibuprofeno Normon 400 mg” e “Ibuprofeno Normon 600 mg” compartían gran parte de su estructura textual. Mantener simultáneamente ambas versiones habría reforzado ciertos patrones léxicos de manera desproporcionada.

Esta decisión no elimina completamente el sesgo del corpus, pero sí reduce parcialmente el riesgo de que el sistema aprenda asociaciones excesivamente dependientes de marcas concretas o estructuras repetidas.

Otro de los problemas detectados apareció durante la extracción del HTML. La simple eliminación de etiquetas estructurales (*tags*) producía con frecuencia fragmentos incompletos o descontextualizados. Muchas advertencias relevantes no estaban contenidas en un único bloque textual, sino repartidas entre una frase introductoria y una lista posterior.

Un ejemplo relativamente habitual era encontrar estructuras como:

“No tome este medicamento si se encuentra en:”

seguidas inmediatamente por una lista HTML con condiciones o contraindicaciones. Si ambos elementos se procesaban de forma independiente, el resultado eran frases semánticamente pobres o incluso ambiguas.

Para reducir este problema se implementó un sistema de segmentación contextual basado en reglas heurísticas. El algoritmo analizaba el árbol DOM del documento, la representación jerárquica del código HTML, y detectaba patrones lingüísticos que indicaban continuidad semántica, como frases terminadas en dos puntos o expresiones condicionales incompletas. Cuando aparecía este tipo de estructura, el sistema concatenaba automáticamente el bloque textual con el siguiente elemento del documento.

Posteriormente, se aplicó un filtrado básico eliminando segmentos inferiores a 50 caracteres. Aunque este umbral puede parecer arbitrario, en las pruebas preliminares permitió reducir gran parte del ruido generado por encabezados aislados, referencias administrativas o fragmentos excesivamente breves que no aportaban contexto suficiente.

Más que “limpiar” el documento, el objetivo de esta fase era preservar unidades mínimas de significado relativamente coherentes antes de transformarlas en vectores semánticos.

3.2.1. Anonimización y Prevención de Sesgos Léxicos

Otro problema importante apareció durante las primeras pruebas de vectorización. Los modelos de *embeddings* tendían a agrupar fragmentos utilizando como referencia principal el nombre del medicamento, incluso cuando las instrucciones pertenecían a contextos distintos. Esto generaba una especie de sobreajuste semántico donde frases procedentes del mismo fármaco quedaban artificialmente próximas aunque hablaran de temas diferentes, mientras que instrucciones funcionalmente equivalentes de medicamentos distintos aparecían alejadas entre sí.

Desde el punto de vista metodológico, esto resultaba problemático porque el objetivo del sistema no era aprender marcas comerciales, sino identificar patrones semánticos entre prospectos.

Para mitigar este efecto se implementó un módulo de anonimización basado en expresiones regulares (*Regex*). El sistema generaba automáticamente un diccionario con los nombres detectados en los prospectos y reemplazaba todas sus apariciones por el token neutro [MEDICAMENTO].

Las reglas se ordenaron jerárquicamente según longitud y especificidad para evitar sustituciones parciales o inconsistentes. De este modo, expresiones completas, variantes comerciales y raíces léxicas relacionadas podían anonimizarse de forma relativamente robusta.

Naturalmente, esta estrategia también tiene limitaciones. Eliminar el nombre del medicamento reduce parte del contexto específico del documento y puede hacer desaparecer asociaciones útiles en determinadas tareas. Sin embargo, en este trabajo el beneficio obtenido sobre la estabilidad de los agrupamientos resultó superior al coste semántico introducido por la anonimización.

3.2.2. Redundancia Estructural y Deduplicación Semántica

A medida que avanzaba el ajuste del número de clusters, apareció un problema que inicialmente no parecía evidente, la redundancia interna de los prospectos oficiales.

Durante las pruebas de agrupamiento se observaron que determinadas instrucciones aparecían repetidas en múltiples clusters distintos. El caso más representativo fue el de las recomendaciones relacionadas con el “olvido de dosis”, que emergían de forma reiterada en grupos semánticos diferentes.

En un primer momento podía parecer un fallo del algoritmo de *clustering*. Sin embargo, al revisar manualmente los fragmentos, se comprobó que el origen real del problema estaba en la propia estructura documental de los prospectos. Muchas advertencias o recomendaciones se repiten parcialmente en distintas secciones regulatorias, utilizando formulaciones ligeramente diferentes pero manteniendo prácticamente la misma intención informativa. Esto introducía una distorsión importante ya que el sistema acababa aprendiendo redundancias administrativas en lugar de relaciones conceptuales.

Como consecuencia, aumentar simplemente el número de clusters (K) dejó de aportar mejoras

reales. De hecho, en algunos casos incrementaba todavía más la fragmentación del contenido. Este hallazgo obligó a introducir una fase previa de deduplicación semántica antes de continuar refinando los modelos de agrupamiento.

Para reducir la redundancia estructural del corpus se implementó un sistema de deduplicación basado en vectores TF-IDF y Similitud del Coseno. A diferencia de los *embeddings* densos, TF-IDF penaliza fuertemente pequeñas diferencias léxicas, lo que lo convierte en una herramienta especialmente útil para detectar duplicados casi literales sin fusionar fragmentos que, aunque parezcan similares, contienen instrucciones diferentes. Esta distinción era importante porque en documentación farmacéutica pequeñas variaciones lingüísticas pueden modificar completamente el significado práctico de una instrucción. Frases aparentemente próximas podían diferir en dosis, restricciones o condiciones de administración.

Para seleccionar el umbral de similitud (τ), se realizó un análisis experimental sobre distintos valores comprendidos entre 0.85 y 0.95. Los umbrales bajos tendían a fusionar instrucciones funcionalmente distintas, generando colisiones semánticas no deseadas. Finalmente, se seleccionó un umbral de $\tau = 0.95$. Aunque esta elección reduce menos texto redundante que configuraciones más agresivas, ofrecía un mejor equilibrio entre limpieza documental y preservación de información diferencial.

La aplicación final del algoritmo permitió eliminar 4720 fragmentos redundantes sobre un corpus inicial de 32499 párrafos, generando un conjunto depurado de 27779 fragmentos únicos. Más allá de la reducción cuantitativa, esta fase mejoró notablemente la estabilidad semántica de los clusters posteriores y permitió que las agrupaciones reflejaran mejor funciones reales en lugar de repeticiones administrativas del propio prospecto.

3.3. Vectorización Semántica en el Espacio Latente

El objetivo de esta fase es transformar las unidades textuales del corpus en representaciones matemáticas densas (*embeddings*) capaces de capturar relaciones de significado más allá de la coincidencia exacta de palabras. Frente a los enfoques clásicos basados únicamente en frecuencia léxica, la vectorización semántica permite modelar afinidades contextuales entre frases que, aunque estén redactadas de forma distinta, transmiten una intención informativa similar.

Muchas instrucciones relevantes aparecen formuladas mediante estructuras lingüísticas diferentes dependiendo del medicamento, del laboratorio o incluso del estilo editorial del documento. Expresiones como “cefalea”, “dolor de cabeza” o “dolor en la cabeza” pueden hacer referencia al mismo concepto, mientras que métodos tradicionales como *Bag of Words*, LDA o TF-IDF tienden a tratarlas como entidades independientes si no comparten suficientes términos exactos.

Por este motivo, antes de abordar el agrupamiento temático del corpus, fue necesario construir un espacio vectorial donde la proximidad geométrica representara forma aproximada la proximidad semántica.

El primer experimento consistió en comprobar si un modelo de *Sentence Embeddings* era capaz de capturar el alineamiento semántico entre los títulos de sección y los fragmentos asociados del prospecto. En este proyecto, el término **alineamiento semántico** se utiliza para describir el grado de coherencia contextual existente entre dos unidades textuales, independientemente de que compartan exactamente las mismas palabras.

Para ello, se utilizó inicialmente el modelo `paraphrase-multilingual-mpnet-base-v2` [16], entrenado mediante arquitecturas tipo *Siamese Network*. Este tipo de modelos proyecta las frases en un espacio vectorial de alta dimensionalidad donde las distancias matemáticas intentan reflejar relaciones de significado.

La comparación entre vectores se realizó mediante la **Similitud del Coseno**, definida como:

$$\text{Similitud}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

Esta métrica se seleccionó porque resulta especialmente adecuada para comparar representaciones densas en espacios de alta dimensionalidad. En lugar de centrarse en la magnitud de los vectores, evalúa la orientación relativa entre ellos, lo que permite medir cercanía conceptual incluso cuando las frases poseen longitudes o estructuras sintácticas distintas.

El propósito inicial era encontrar un umbral de similitud (τ) que permitiera discriminar automáticamente si un párrafo mantenía suficiente relación semántica con el título de su sección. Para validar esta idea, se compararon las predicciones automáticas frente al *Gold Standard* construido manualmente en el dataset exploratorio (D_{exp}), utilizando curvas *Precision-Recall* y métricas F1-Score (Figura 3.1).




Figura 3.1: Curvas de Precision-Recall y F1-Score en el análisis manual.

El sistema identificó un umbral matemáticamente óptimo en $\tau = 0,0104$, alcanzando un F1-Score de 0.9054. Sin embargo, un análisis más detallado mostró que esta precisión estaba condicionada por el desbalanceo del dataset. La matriz de confusión mostró una cantidad elevada de falsos positivos frente a una detección mínima de verdaderos negativos.

Más allá del valor numérico de la métrica, lo interesante fue observar cómo estaban divididas las frases en el espacio vectorial. Existía un solapamiento considerable entre fragmentos administrativos, advertencias generales e instrucciones. Además, muchos títulos de sección resultaban excesivamente amplios y actuaban como categorías genéricas capaces de contener información muy distinta entre sí.

Esto introducía una limitación metodológica. El problema no parecía residir únicamente en el modelo de embeddings, sino también en la propia organización interna de los prospectos. En documentos regulatorios, distintas advertencias pueden estar bajo encabezados muy ambiguos, lo que dificulta establecer fronteras semánticas limpias mediante clasificadores binarios. Por lo tanto, se descartó el uso de umbrales estáticos como mecanismo principal de separación semántica. En su lugar, se optó por técnicas de aprendizaje no supervisado capaces de modelar distribuciones temáticas más complejas sin depender de decisiones lineales rígidas.

3.3.1. Selección de Arquitecturas y Modelos de *Embeddings*

Una vez confirmado que el enfoque basado exclusivamente en umbrales resultaba insuficiente, el siguiente objetivo fue seleccionar arquitecturas de vectorización adecuadas para las distintas fases del proyecto. La decisión no dependía únicamente de la calidad semántica del modelo, sino también de cuestiones prácticas relacionadas con escalabilidad, coste computacional y estabilidad en español.

Para ello, en una primera prueba de descubrir los temas de los prospectos, se evaluaron tres modelos distintos de representación temática:

1. **Latent Dirichlet Allocation (LDA)** [13]: modelo probabilístico basado en coocurrencia de palabras.
2. **Non-negative Matrix Factorization (NMF)** [32]: aproximación algebraica apoyada en matrices TF-IDF.
3. **Clustering semántico sobre embeddings**: enfoque basado en aprendizaje profundo donde las frases son transformadas en vectores densos antes de aplicar algoritmos de agrupamiento.

Los métodos clásicos mostraron ciertas limitaciones. Aunque LDA y NMF funcionan razonablemente bien cuando los tópicos poseen vocabulario muy diferenciado, suelen dividir conceptos equivalentes expresados con distintos términos. Esto resulta problemático en prospectos médicos, donde pequeñas variaciones léxicas son frecuentes y no siempre implican diferencias reales de significado. Por el contrario, los modelos de embeddings permitían capturar relaciones contextuales más robustas. Frases como “qué hacer si olvida una dosis” y “si se le olvidó tomar el medicamento” tendían a converger en regiones próximas del espacio latente pese a no compartir exactamente la misma estructura sintáctica.

No obstante, también aparecieron limitaciones relevantes. La proximidad vectorial no garantiza necesariamente equivalencia conceptual absoluta. En los textos dos frases pueden parecer semánticamente cercanas y, aun así, diferir en matices importantes relacionados con dosis, restricciones o advertencias específicas.

En fases posteriores, se adoptó una estrategia escalonada utilizando modelos distintos según la fase experimental:

- **Modelo base de desarrollo:** Para las tareas de exploración masiva y clustering del dataset D_{base} se empleó `paraphrase-multilingual-MiniLM-L12-v2`. Este modelo ofrecía un equilibrio razonable entre velocidad, coste computacional y capacidad semántica multilingüe.
- **Modelo de alta resolución semántica:** En fases posteriores de validación y análisis fino se utilizó `multilingual-e5-large`, seleccionado por su mayor sensibilidad a diferencias contextuales sutiles en español.

La utilización de dos arquitecturas se debió a que modelos grandes suelen proporcionar representaciones más precisas, pero también introducen mayores costes de procesamiento que habrían complicado las etapas exploratorias tempranas en las que se utilizaban muchos más datos. Por ello, se reservó el uso de arquitecturas de mayor capacidad para escenarios donde el alineamiento semántico fino tenía un impacto directo sobre la evaluación final.

Finalmente, una vez obtenidas las representaciones vectoriales del corpus limpio y anonimizado, estas fueron utilizadas como entrada para los algoritmos de agrupamiento descritos en la siguiente sección. El objetivo ya no era clasificar fragmentos mediante reglas rígidas, sino explorar la estructura topológica del espacio semántico e identificar agrupaciones temáticas emergentes dentro de los prospectos.

3.4. Clustering y Optimización Topológica

El objetivo de esta fase es identificar la estructura temática latente de los prospectos médicos mediante técnicas de agrupamiento no supervisado. A diferencia de los enfoques basados en clasificación binaria, el propósito aquí no es decidir si un fragmento pertenece o no a una categoría concreta, sino descubrir automáticamente cómo se organiza la información clínica y qué nivel de granularidad resulta más útil para representar las necesidades reales de un paciente.

3.4.1. Selección del Número Óptimo de Clústeres

Para dividir las frases de los prospectos en clústeres se seleccionó el algoritmo K-Means ya que, aunque los prospectos tengan información administrativa no tan importante para el paciente, para que el sistema sea robusto y no pierda información no se pueden descartar fragmentos. Uno de los principales retos de cualquier algoritmo particional como K-Means consiste en definir previamente el número de agrupaciones (K). Dado que no existía una referencia objetiva sobre cuántas categorías temáticas podían emerger de los prospectos médicos, se diseñó un proceso de experimentación para evaluar diferentes configuraciones dentro del rango $K \in [6, 20]$. El valor mínimo ($K = 6$) se estableció tomando como referencia las secciones regulatorias tradicionales de los prospectos oficiales. El valor máximo ($K = 20$) se eligió porque una fragmentación demasiado grande no favorece a la búsqueda de información.

Con el objetivo de evitar una elección arbitraria, la calidad de las agrupaciones se evaluó utilizando tres métricas complementarias, cada una orientada a analizar una propiedad distinta de la estructura generada.

- **Perplejidad (LDA):** utilizada para evaluar la capacidad predictiva del modelo probabilístico sobre documentos no observados previamente:

$$\text{Perplexity}(D) = \exp \left(- \frac{\sum_{d=1}^M \log p(\mathbf{w}_d)}{\sum_{d=1}^M N_d} \right)$$

donde M representa el número de documentos, $\mathbf{w}_d$ las palabras del documento d y N_d el número total de palabras. Valores más bajos indican una mejor capacidad de modelado.

- **Inercia o Método del Codo (K-Means):** mide la dispersión interna de los clústeres mediante la suma de distancias cuadráticas entre cada punto y su centroide:

$$\text{Inercia} = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

donde μ_j representa el centroide del clúster C_j . El objetivo es localizar el punto de inflexión donde aumentar el número de grupos deja de aportar mejoras relevantes.

- **Coeeficiente de Silueta (K-Means):** evalúa simultáneamente la cohesión interna y la separación entre clústeres:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

donde $a(i)$ representa la distancia media entre un punto y los elementos de su mismo clúster, mientras que $b(i)$ mide la distancia media al clúster vecino más cercano. Valores cercanos a 1 indican agrupaciones más consistentes.

Los resultados mostraron ligeras diferencias entre las métricas estadísticas y geométricas. Mientras que la Perplejidad de LDA sugería mínimos locales en $K = 12$ y $K = 14$, las métricas aplicadas sobre los embeddings semánticos mostraron un comportamiento diferente. La curva de Inercia presentó un punto de inflexión en $K = 11$, y el Coeficiente de Silueta alcanzó máximos locales en $K = 11$, $K = 13$ y $K = 15$, aunque se detectaron otros máximos locales con mayor valor de K se decidió limitar el estudio hasta $K = 15$.

A partir de este análisis, se seleccionó inicialmente $K = 11$ como configuración de referencia, al ser el único valor respaldado simultáneamente por dos heurísticas independientes. La Figura 3.2 resume el resultado de las métricas evaluadas durante el proceso de optimización.




Figura 3.2: Evolución de las métricas de Perplejidad, Inercia y Coeficiente de Silueta durante la búsqueda del número óptimo de clústeres.

Una vez identificado el rango óptimo de valores para K , se compararon distintas herramientas de modelado temático sobre el dataset D_{topic} .

Se evaluaron tres aproximaciones:

1. **LDA (*Latent Dirichlet Allocation*) [13]:** basado en distribuciones probabilísticas de palabras.
2. **NMF (*Non-negative Matrix Factorization*) [32]:** construido sobre representaciones TF-IDF.
3. **K-Means sobre embeddings semánticos [14]:** utilizando representaciones densas generadas mediante modelos multilingües de *Sentence Embeddings*.

La comparación mostró limitaciones en los métodos clásicos basados en frecuencia léxica. Debido a que los prospectos comparten una gran cantidad de vocabulario común (“medicamento”, “dosis”, “tratamiento”, “efectos adversos”), tanto LDA como NMF tendían a generar agrupaciones dominadas por términos muy repetitivos, lo que dificultaba una separación temática útil.

Por el contrario, el enfoque basado en embeddings permitió capturar relaciones de significado más allá de la coincidencia exacta de palabras. Por ejemplo, frases como “dolor de cabeza” y “cefalea” se proyectaron en regiones cercanas del espacio vectorial, permitiendo que el algoritmo las agrupase dentro de un mismo contexto temático.

3.4.2. Partición Semántica Inicial ($K = 11$)

Con el corpus D_{base} ya preprocesado y anonimizado, se procedió a ejecutar la primera partición semántica completa utilizando el modelo `paraphrase-multilingual-MiniLM-L12-v2`. Este modelo fue seleccionado por ofrecer un equilibrio adecuado entre capacidad semántica y coste computacional durante el procesamiento de párrafos.

Cada fragmento textual fue transformado en un vector denso y posteriormente agrupado mediante K-Means utilizando una semilla determinista (`random_state`) y el valor óptimo inicial de $K = 11$.

La inspección manual de los clústeres mostró que el sistema era capaz de reconstruir de forma no supervisada gran parte de la organización funcional de un prospecto médico. Surgieron agrupaciones diferenciadas relacionadas con contraindicaciones, embarazo, conservación, interacciones farmacológicas o advertencias generales para el paciente.

No obstante, había ruido estructural y agrupaciones excesivamente heterogéneas. Algunos clústeres mezclaban instrucciones procedimentales distintas, mientras que otros fragmentaban temas equivalentes en múltiples grupos independientes.

Con el objetivo de analizar cómo afectaba el nivel de granularidad a la calidad semántica de las agrupaciones, se realizaron experimentos sucesivos aumentando el número de clústeres.

ID	Tópico Inferido	Ejemplo Representativo
0	Encabezado e identificación	<i>“Prospecto: información para el usuario...”</i>
1	Contraindicaciones	<i>“Si ha padecido mastocitosis...”</i>
4	Embarazo y lactancia	<i>“Si se encuentra en el tercer trimestre...”</i>
7	Interacciones medicamentosas	<i>“Si está en tratamiento con medicamentos...”</i>
8	Indicaciones terapéuticas	<i>“Está indicado para prevenir la formación de trombos...”</i>
9	Conservación	<i>“Conservar por debajo de 25°C.”</i>

Tabla 3.1: Ejemplos de agrupaciones semánticas generadas mediante K-Means sobre embeddings densos ($K = 11$).

3.4.3. Configuración de 13 Clústeres

El incremento a $K = 13$ permitió aislar con mayor claridad determinados contextos que permanecían mezclados en la configuración anterior. Surgieron agrupaciones específicas relacionadas con instrucciones mecánicas de administración, inicio del tratamiento y advertencias vinculadas al estilo de vida del paciente.

Sin embargo, esta mejora vino acompañada de nuevos problemas estructurales. Se observó una fragmentación excesiva de temas recurrentes, especialmente en instrucciones relacionadas con el olvido de dosis, que aparecían distribuidas en múltiples clústeres distintos dependiendo del formato farmacéutico o del estilo de redacción utilizado en los prospectos originales.

Además, algunos grupos se volvieron demasiado generales, acumulando fragmentos con baja cohesión semántica.

3.4.4. Configuración de 15 Clústeres

Como con $K = 13$ algunos temas seguían mezclados, se aplicó una configuración de $K = 15$, resultado obtenido con el Coeficiente de Silueta, que permitió separar con mayor precisión tópicos clínicos especialmente sensibles, como las advertencias sobre conducción o embarazo. Desde el punto de vista geométrico, el modelo conseguía aislar regiones temáticas muy específicas dentro del espacio latente.

Sin embargo, este incremento de resolución también mostró una saturación semántica. La excesiva fragmentación provocó que instrucciones equivalentes aparecieran repartidas en múltiples clústeres distintos, dificultando la posterior abstracción de categorías universales.

Este comportamiento sugirió que la redundancia de los clústeres venía influenciada por la repetición de la información en los propios prospectos. Muchas advertencias aparecen repetidas en distintas secciones y en ocasiones con formulaciones diferentes. Al haber tantas frases idénticas junto a otras semánticamente parecidas pero redactadas de distinta forma, el sistema agrupa las frases léxicamente iguales en un mismo clúster, pero no logra identificar el resto debido al uso de términos distintos.

Como ya se ha mencionado en la sección previa, para reducir el efecto de esta redundancia, se incorporó una fase adicional de deduplicación semántica antes de continuar con las siguientes iteraciones de clustering. Finalmente se eliminaron 4.720 fragmentos redundantes de un total inicial de 32.499 párrafos, obteniendo un corpus final compuesto por 27.779 unidades textuales únicas.

Con la base de datos optimizada se reevaluó $K = 15$ para ver si mejoraba la fragmentación. Sin embargo, se detectaron errores que hicieron que se evaluara un número menor de agrupaciones. Resultó que surgieron clústeres que agrupaban frases demasiado específicas, como frases sobre psoriasis o la

reacción con cosméticos.

3.4.5. Configuración de 14 Clústeres

Tras ver que los 15 clústeres eran demasiado específicos, se repitieron los experimentos de clustering utilizando una configuración menor ($K = 14$) con el objetivo de encontrar un equilibrio entre cohesión temática y capacidad de generalización.

Los resultados mostraron de nuevo que 14 clústeres fragmenta demasiado la información y las agrupaciones se vuelven híper-específicas. Por lo que se redujo aún más el número de clústers, $K = 12$, una de las opciones que se consiguió en el cálculo de la perplejidad durante el análisis de tópicos. El propósito final era obligar al algoritmo a fusionar los temas demasiado específicos sin perder información.

3.4.6. Configuración de 12 Clústeres

El objetivo de esta fase fue encontrar el punto de equilibrio ideal, un número de grupos lo suficientemente pequeño para evitar repeticiones, pero lo bastante grande para no perder detalles importantes sobre la seguridad del paciente como pasaba con los 11 clústeres previamente analizados.

Para este experimento, se utilizó el corpus ya optimizado. El resultado fueron grupos temáticos en los que la mayor parte de las frases correspondían a un solo tema clínico, además, se lograban identificar temas como el embarazo o la conducción correctamente.

Este comportamiento confirmó que la calidad de las agrupaciones no depende únicamente del algoritmo de clustering o del modelo de embeddings utilizado, sino también de la calidad estructural del corpus y del grado de redundancia presente en los datos originales.

Con los resultados conseguidos con esta configuración ($K = 12$), se procedió a la siguiente fase: la síntesis de preguntas maestras mediante grandes modelos de lenguaje.

Aumento del tamaño del corpus:

Antes de pasar a la fase de síntesis generativa, surgió una hipótesis de si aumentar el tamaño del dataset podría mejorar la precisión del sistema. Por lo que se construyó el corpus D_{scale} con 1000 prospectos diferentes siguiendo el mismo procedimiento que con el dataset base.

Los resultados mostraron que aumentar la muestra no aportó diversidad y 5 de 12 clústeres juntaban frases de la misma temática. No obstante, se decidió evaluar esta configuración en la fase de generación de preguntas maestras para comprobar si los LLMs eran capaces de encontrar patrones distintos entre esos clústeres.

3.5. Síntesis Generativa de Preguntas Maestras

Una vez definida la estructura de los clústeres mediante el análisis experimental previo, comenzó la fase de síntesis generativa. El objetivo de esta etapa fue comprobar si un LLM era capaz de interpretar el contenido semántico de cada agrupación y transformarlo en una sola pregunta que recogiera la duda principal que tiene un paciente cuando busca esas frases.

Para evitar respuestas erróneas o demasiado específicas, se diseñó un sistema de inferencia controlado mediante técnicas de prompt engineering. El modelo debía comportarse como un paciente real con una duda urgente y no como un redactor técnico.

El prompt incluía varias restricciones:

- **Role-Prompting (Empatía cognitiva):** Se forzó al modelo a asumir el rol de un “paciente con una duda urgente”, induciendo un registro lingüístico coloquial, directo y alejado de la jerga clínica.
- **Restricciones Negativas (Negative Prompting):** Se prohibió explícitamente el uso de metadatos del corpus (palabras como “prospecto”, “fragmento”, “sección”) y se vetó la mención de nombres de utensilios de fármacos (jeringa, pluma...), garantizando la universalidad de la pregunta generada.
- **Few-Shot Learning (Razonamiento guiado):** Se incluyeron ejemplos de la lógica interna esperada, mostrando cómo mapear una directriz clínica (ej. “*Estas dosis se pueden repetir cada 4 horas*”) a una pregunta funcional (ej. “*¿Cada cuánto tiempo me lo tengo que tomar?*”).
- **Formateo Estructurado:** Para permitir la automatización del *pipeline*, se forzó la salida del modelo en un formato de datos serializado (JSON).

Para garantizar la robustez de las preguntas generadas y evitar sesgos de un único modelo, se implementó un enfoque de validación por comité (*Ensemble*).

Para las primeras iteraciones evaluaron secuencialmente variaciones del modelo de código abierto Llama-3 de Meta [24] (`llama3:latest`, `llama3_medium:latest`, `llama3_hard:latest`), inyectando muestras representativas de cada uno de los 11 clústeres y auditando las respuestas generadas. La inferencia se orquestó de forma local utilizando el motor Ollama desplegado en los servidores de la Universidad Politécnica de Madrid (UPM), accediendo mediante red privada virtual (VPN).

Durante el desarrollo experimental no se generaron preguntas únicamente para la arquitectura final. Se probó a generar preguntas con todas las configuraciones vistas en la fase de clustering con el objetivo de entender cómo afectaba la granularidad semántica al comportamiento de los LLMs.

Esta fase exploratoria fue clave para identificar cuándo los clústeres eran demasiado amplios y mezclaban temas incompatibles, cuándo una fragmentación excesiva generaba preguntas muy específicas, qué tipos de agrupaciones favorecían la generación de preguntas universales y qué modelos eran más estables y obedientes a las instrucciones.

Por lo tanto, las distintas configuraciones de K-Means representaron etapas necesarias de validación metodológica que permitieron construir la arquitectura definitiva.

Generación para 11 clústeres:

La primera arquitectura evaluada fue la configuración base de $K = 11$.

Los resultados identificaron secciones robustas en aquellas donde los tres modelos alcanzaron un consenso semántico, es decir, las preguntas hablaban del mismo tema común. Destacaron el Clúster 4 (“*¿Qué hago si se me olvida una dosis?*”), el Clúster 7 para emergencias (“*¿Qué debo hacer si tengo una reacción alérgica grave?*”) y el Clúster 9 centrado en efectos secundarios (“*¿Cuáles son los efectos secundarios peligrosos?*”). En estos nodos, el modelo demostró que sintetizaba la información correctamente. Sin embargo, se observaron inestabilidades que invalidaron su uso como arquitectura final. En primer lugar, el algoritmo K-Means agrupó las frases basándose en el formato físico del medicamento en lugar de en la intención procedimental. Por ejemplo, la advertencia sobre “olvido de dosis” apareció fragmentada en los clústeres 4, 6, 8 y 10. Además, el clúster 5 colapsó agrupando párrafos hiper-específicos (métodos de aplicación de geles o colirios) sin ninguna cohesión temática transversal, generando preguntas inservibles. Y variables importantes para la seguridad del paciente, como las interacciones durante el **embarazo** o la afectación a la **conducción**, no lograron independizarse geométricamente, quedando categorizadas como ruido secundario dentro de clústeres más grandes.

Aunque los 11 clústeres eran matemáticamente coherentes, la información se comprimía de manera excesiva y los LLMs no eran capaces de encontrar un tema predominante. Como ya ha sido mencionado

en la fase anterior, el número de clústeres se fue aumentando conforme se analizaban las agrupaciones formadas.

Generación para 13 clústeres:

De nuevo, se utilizó el comité de los modelos Llama-3 y el mismo prompt detallado.

Al analizar las nuevas preguntas generadas por los LLMs, se mostró una evolución respecto a la agrupación anterior. El modelo logró aislar las dudas sobre el momento exacto de la primera toma (por ejemplo: “¿Cuándo puedo empezar con la primera tira del blíster?”). También, consiguió separar las instrucciones mecánicas más complejas, aunque muy específicas, como la forma correcta de usar un inhalador o un supositorio. Y por primera vez, apareció un grupo independiente que trataba temas del día a día, como el consumo de alcohol o posibles problemas de visión al tomar el fármaco.

No obstante, a pesar de estas mejoras, también presentó limitaciones. De nuevo, la duda sobre el “olvido de una dosis” se fragmentó en exceso y apareció en seis grupos diferentes (4, 6, 7, 8, 10 y 12). El algoritmo separó estas frases porque el texto original las escribe de forma distinta según si habla de pastillas, parches o jarabes. Sin embargo, para el paciente, la duda principal sigue siendo la misma. Además, se generaron frases de relleno, por ejemplo en el clúster 2 (“¿Qué debo hacer?”). En el caso del clúster 12, se creó un grupo genérico que mezclaba instrucciones referentes a sobredosis, con las de olvido de dosis y otros temas con diferente significado semántico.

Aunque aumentar a 13 clústeres permitió rescatar instrucciones específicas de uso, la información seguía estando repetida. Por este motivo, se decidió que era necesario dar un paso más y explorar un modelo de 15 clústeres.

Generación para 15 clústeres:

Una vez más se utilizó el mismo procedimiento que para las agrupaciones anteriores. El objetivo principal era comprobar si esta alta fragmentación lograba separar definitivamente riesgos críticos para el paciente, como la conducción o el embarazo y estos se veían reflejados en las preguntas generadas.

Los resultados representaron preguntas con contenido que no se había visto en configuraciones anteriores gracias a la fragmentación. Se identificaron preguntas de conducción (por ejemplo: “¿Puedo conducir o manejar maquinaria después de tomar esto?”); y se creó un grupo exclusivo para la información sobre el embarazo (por ejemplo: “¿Puedo seguir tomando el medicamento si estoy embarazada?”).

Sí bien es cierto que se consiguieron 9 clústeres en los que los modelos de síntesis generativas coincidieron, los ocho restantes abarcaban frases muy concretas. Además, de nuevo se repitió el tema del “olvido de dosis” que apareció repetido en 5 grupos distintos (1, 5, 6, 8 y 14). Para solucionar esto, como se ha mencionado en la sección anterior, se aplicó una deduplicación semántica.

Una vez limpia la base de datos se volvieron a comprobar las preguntas generadas para los 15 clústeres. Para ello, se utilizaron los modelos llama-3 y el mismo prompt detallado. Los resultados siguieron la línea de lo visto en la fase previa de clusterización. En lugar de generar preguntas universales, los modelos se centraron en palabras demasiado concretas presentes en el clúster. Esto generó preguntas inservibles a nivel general, como “¿Puedo llevar a mi hijo a tomar un baño mientras utilizo el medicamento para el glaucoma?” (Clúster 6) o dudas hiper-específicas sobre cosméticos y psoriasis (Clúster 3). Además, varios modelos perdieron su configuración base. En clústeres como el 4 o el 9, la versión *Llama3_latest* rompió el formato JSON obligatorio y también comenzó a responder en inglés (“What are the possible side effects...”). En el clúster 12 los modelos generaron preguntas sobre temas completamente distintos (lactancia, conducción y uso pediátrico) y en el clúster 11 uno de los modelos sufrió una alucinación y generó la pregunta “¿Qué es lo que esto es?”.

Después de esta prueba surgió la pregunta experimental de si era el prompt excesivamente largo el que provocaba estas alucinaciones o era la capacidad limitada de los modelos. Para descartar que el fallo viniera de la capacidad de los modelos se utilizó un nuevo comité formado por tres modelos más avanzados, de nuevo ejecutados a través de la API de Ollama y el servidor de la UPM.

- **Llama-3.1 (70B) [24]:** Desarrollado por Meta, es un modelo masivo de 70 billones de parámetros, conocido por su enorme capacidad de comprensión y razonamiento general.
- **DeepSeek-R1 (32B) [23]:** Un modelo de 32 billones de parámetros especializado en razonamiento lógico profundo.
- **Gemma-3 (27B) [26]:** Creado por Google, destaca por su altísima eficiencia y precisión técnica con 27 billones de parámetros.

Además, se simplificó drásticamente el diseño del prompt para reducir la carga cognitiva de los modelos durante la inferencia. Se eliminaron todas las reglas estrictas de la fase anterior y se empleó una orden muy básica y directa: *“A partir de estos fragmentos de un prospecto médico, genera una pregunta breve que un paciente haría para obtener esta información”*.

El objetivo era comprobar si la potencia de cálculo de estos LLMs era suficiente para entender los grupos de frases por sí solos, sin necesidad de que fueran guiados con reglas complejas. Se volvió a aplicar el mismo proceso que para pruebas anteriores: hacer llamadas a los grandes modelos de lenguaje para cada clúster con el prompt simple y las frases correspondientes.

Las preguntas generadas demostraron que, a pesar de usar una potencia computacional mayor, utilizar un *prompt* tan simple produce resultados inútiles para nuestro objetivo de crear un sistema de preguntas universales. Los principales fallos fueron:

1. **Alucinaciones por exceso de detalle:** Al leer párrafos con ejemplos muy concretos, los modelos asumen erróneamente que todo el prospecto trata sobre esa enfermedad. Por ejemplo, en el Clúster 8, Llama-3.1 generó una pregunta exclusiva para el **VIIH**. De la misma forma, en el Clúster 13, Gemma-3 asumió que todos los textos hablaban del **ácido acetilsalicílico** (Aspirina). Esto destruye la universalidad de la pregunta.
2. **Desobediencia de idioma:** A pesar de que las instrucciones del sistema estaban escritas en castellano, el modelo DeepSeek-R1 respondió en inglés en el Clúster 6 (*“Who should not take [MEDICAMENTO]?”*).
3. **Límites técnicos (Caídas del servidor):** Mover modelos matemáticos de razonamiento exigen más memoria y potencia gráfica. Durante el experimento, los servidores no pudieron soportar la carga provocando tiempos de espera agotados (*Timeouts*) que dejaron los clústeres 10 y 11 sin respuesta por parte de DeepSeek-R1.

Después de este experimento se concluyó que el problema no era el tamaño de los modelos sino la extrema especificidad de los datos. Como ya se mencionó, esta agrupación creaba clústeres con frases muy concretas y específicas. Por esta razón se redujo a 14 clústeres y, una vez más, se evaluaron las preguntas generadas.

Generación para 14 clústeres:

Para esta generación de preguntas se utilizaron los modelos (*Llama-3 de 8B*, *DeepSeek-R1 de 32B* y *Gemma-3 de 27B*) y se volvió a un prompt muy extenso y detallado. Como ya se había utilizado previamente, este prompt contaba con: “Juego de Rol”, tenía que actuar como un paciente con una duda urgente para forzar lenguaje natural y sencillo; reglas prohibitivas, para evitar palabras técnicas y nombres de componentes; y few-shot learning, proporcionando ejemplos de cómo razonar para obtener la pregunta.

Al ejecutar este prompt sobre los modelos se observó:

- **Llama-3 (8B):** este modelo demostró no tener suficiente capacidad de abstracción. Siguió dejándose engañar por palabras concretas. Por ejemplo, en el Clúster 13, asumió erróneamente que todos los textos hablaban de tratar la malaria con hidroxycloroquina.

- **DeepSeek-R1 (32B):** Este modelo resultó ser demasiado inestable. Por un lado, nuevamente provocó múltiples caídas en el servidor (Errores 500). Por otro lado, sufrió una grave confusión de idiomas (*Token Bleed*) ya que en el Clúster 7 mezcló el español con el término árabe (*Al-Janib*), intentando traducir literalmente la palabra “lado” o “efecto secundario”.
- **Gemma-3 (27B):** El modelo de Google fue el único capaz de interpretar el razonamiento guiado. Logró ignorar los nombres de componentes concretos y generó preguntas universales precisas, seguras y escritas como un paciente real (ej. “¿Qué riesgos tiene este medicamento si estoy embarazada, planeo quedar embarazada o estoy dando el pecho?”).

Aunque las preguntas generadas por Gemma-3 estaban correctamente redactadas, con coherencia léxica, muchas se solapaban entre sí. Por ejemplo, había varias preguntas distintas dedicadas exclusivamente a los efectos secundarios. Para un paciente real, enfrentarse a un índice con 14 opciones muy parecidas supone un esfuerzo mental excesivo (carga cognitiva), lo cual va en contra del objetivo principal de este trabajo.

Con este experimento se concluyó que, incluso con los datos limpios y la mejora de los modelos, catorce grupos son demasiados. Por lo que se decidió disminuir la resolución, como ya quedó explicado en la clusterización, y probar con 12 clústeres, una de las opciones conseguidas en el cálculo de la perplejidad durante el análisis de tópicos.

Generación para 12 clústeres:

El objetivo de reducir la división es obligar a “fusionar” estas preguntas tan repetitivas en categorías universales mucho más amplias, útiles y fáciles de leer para el usuario final.

Para mejorar la calidad de las preguntas, se refinó la instrucción (prompt) enviada a los modelos. En esta versión, se incluyó una regla lógica nueva en la que se solicitó a los LLMs que identificaran el tema presente en el **80 % de los fragmentos** de cada grupo, ignorando detalles que solo aparecieran una vez. Con esto, se buscó que las preguntas fueran generales y universales, evitando que la mención a un síntoma raro o a un formato específico (como un gel o un parche) desviara la atención del tema principal.

Después se repitió el mismo proceso realizado para las iteraciones previas. Los resultados fueron los siguientes para los tres modelos:

1. **DeepSeek-R1 32B:** Aunque este modelo es muy capaz a la hora de razonar, su gran tamaño provocó fallos críticos en casi la mitad de las peticiones (Clusters 4, 6, 8 y 9). Los servidores sufrieron errores de tiempo de espera (*Timeouts*), lo que demuestra que este modelo, aunque potente, es difícil de integrar en un sistema que deba responder de forma ágil y constante.
2. **Llama3-hard 8B:** Este modelo de menor tamaño mostró dificultades para seguir reglas estrictas de formato. A pesar de que se le ordenó responder exclusivamente en formato JSON, el modelo incluyó comentarios adicionales y explicaciones innecesarias (ej: “El tema que se repite es...”). Esto supone un problema técnico, ya que obliga a limpiar el texto antes de que otros programas puedan usarlo.
3. **Gemma-3 27B:** El modelo entendió su papel como “paciente”, no inventó nombres de fármacos y generó preguntas muy naturales y precisas. Su único hábito fue devolver las respuestas dentro de bloques de código (Markdown), un detalle menor que es fácil de corregir automáticamente.

Sin embargo, estos resultados revelaron una debilidad del sistema, el único modelo que había conseguido resultados adecuados en todos los clústeres era Gemma-3. No se podía depender de un único modelo para dar por válidas las preguntas maestras. Deepseek, a pesar de dar fallos por Timeout en varias agrupaciones, consiguió coincidir con Gemma-3 en muchas otras con preguntas naturales. Sin embargo, Llama-3 no fue capaz de obedecer reglas estrictas de formato y en ocasiones alucinaba. Por lo tanto, el siguiente paso metodológico consistió en ampliar el comité de evaluación a cinco modelos grandes de lenguaje:

1. **Gemma-3 (27B)[26]:** De nuevo. Desarrollado por Google, con 27 billones de parámetros. Se consolidó en las fases previas como el modelo más fiable de este proyecto gracias a su capacidad de abstracción y su estricto seguimiento de las instrucciones de formato.
2. **GPT-OSS (120B)[28]:** Un modelo masivo de código abierto con 120 billones de parámetros. Su tamaño le otorga una comprensión del lenguaje casi perfecta, asegurando que las preguntas generadas tengan una gran coherencia gramatical y no pierdan el contexto médico.
3. **DeepSeek-R1 (32B) [23]:** Un modelo de 32 billones de parámetros altamente especializado en razonamiento lógico deductivo. Su función en el comité es asegurar que la conexión lógica entre el texto del prospecto y la pregunta generada sea exacta.
4. **Nemotron-3-Nano (30B) [27]:** Desarrollado por la empresa Nvidia, este modelo de 30 billones de parámetros está optimizado específicamente para tareas de recuperación de información y síntesis, haciéndolo ideal para resumir grandes bloques de texto.
5. **Qwen-3 (30B) [25]:** Desarrollado por Alibaba, este modelo destaca a nivel mundial por su excelente manejo del multilingüismo. Se incluyó para asegurar que el procesamiento del español médico fuera preciso y natural.

El objetivo de esta ampliación era buscar alternativas viables de tamaño medio que ofrecieran un equilibrio entre capacidad de razonamiento, obediencia de reglas y agilidad en el servidor. Utilizando el prompt refinado, que exigía que el modelo se fijara en el contenido repetido en el 80 % de los fragmentos, se volvió a seguir el mismo proceso que en apartados anteriores.

Al ejecutar el comité sobre los 12 clústeres definitivos, el sistema demostró la enorme ventaja de utilizar múltiples grandes modelos de lenguaje en paralelo. Los resultados fueron los presentados en la Tabla 3.2:

La estrategia del comité pentapartito permitió evitar los fallos técnicos que se habrían enfrentado si se hubiera dependido de un solo sistema. Aunque también hubo fallos.

El modelo DeepSeek-R1 volvió a sufrir caídas de servidor (Errores 500) en varios clústeres debido a su gran consumo de memoria. No obstante, al tener otros cuatro modelos respondiendo simultáneamente, el sistema no se detuvo y pudo extraer la información sin problemas.

En el Clúster 6 (relativo a la conducción), el modelo Nemotron sufrió un fallo de alineación y respondió en inglés (*“Is it safe to drive...”*). Gracias al comité, esta respuesta atípica pudo ser ignorada, ya que los otros cuatro modelos generaron preguntas coherentes en castellano (ej. *“¿Puedo conducir o usar maquinaria mientras estoy tomando este medicamento?”*).

Después de la generación de estas 60 preguntas (5 para cada uno de los 12 clústeres) se consiguieron aislar dudas procedimentales como la dosis recomendada (clúster 0), el embarazo y la lactancia (clúster 1), el olvido de tomas (clúster 2) y los efectos secundarios (clúster 3).

Experimento de escalado

Como se comentó en la fase anterior, se quiso comprobar si aumentando el tamaño del corpus se conseguían resultados más precisos. Para generar las preguntas sobre esta cantidad de texto, se optó por un comité de modelos de lenguaje seleccionados específicamente por su capacidad para procesar grandes volúmenes de información sin sufrir caídas en el servidor:

1. **Qwen-2.5 (32B):** Sustituyó a DeepSeek-R1. Ofrece un rendimiento sobresaliente en seguimiento de instrucciones y capacidad de abstracción, solucionando los problemas de latencia y caídas de red observados previamente.
2. **Gemma-3 (27B):** Mantenido por su rendimiento perfecto a la hora de adoptar el rol de paciente.
3. **Llama3-hard (8B):** Utilizado como modelo de control estricto para comparar resultados con una arquitectura de menor tamaño.

Tabla 3.2: Resultados de la Síntesis Generativa: Comité Pentapartito ($K = 12$)

ID	Qwen-3	DeepSeek-R1	Gemma-3	GPT-OSS	Nemotron-3
0	¿Este medicamento es exento de sodio? ¿Cuál es la dosis correcta para este medicamento y cómo se toma? ¿Cómo debo tomar este medicamento y cada cuánto tiempo? ¿Cuál es la dosis recomendada de este medicamento? ¿Cuál es la dosis y la frecuencia de administración?				
1	¿Puedo tomar este medicamento si estoy embarazada o en periodo de lactancia? ¿Cuáles son las advertencias que deben tener las mujeres embarazadas y en periodo de lactancia al momento de usar medicamentos? ¿Puedo tomar este medicamento si estoy embarazada, planeo quedar embarazada o estoy amamantando? ¿Puedo tomar este medicamento si estoy embarazada o amamantando? ¿Puedo tomar el medicamento si estoy embarazada o amamantando?				
2	¿Qué hago si olvido una dosis? ¿Qué debo hacer si olvido tomar una dosis? ¿Cómo debo tomar este medicamento y qué hago si olvido una dosis? ¿Qué debo hacer si olvido o pierdo una dosis de mi medicamento? ¿Qué debo hacer si olvido tomar una dosis de mi medicamento?				
3	¿Este medicamento puede causar erupciones en la piel con ampollas? ¿Qué efectos adversos pueden presentar en los ojos durante el tratamiento médico? ¿Cuáles son los posibles efectos secundarios de este medicamento, especialmente aquellos que requieren atención médica inmediata o que afectan a los ojos? ¿Cuáles son los efectos secundarios o reacciones adversas que puedo presentar con este medicamento? ¿Qué signos indican que debo dejar de tomar el medicamento y buscar ayuda médica inmediata?				
4	¿Qué efectos secundarios puede causar este medicamento? <i>ERROR_SERVIDOR</i> ¿Cuáles son los posibles efectos secundarios o problemas que debo tener en cuenta al tomar este medicamento y cuándo debo buscar ayuda médica? ¿Puedo conducir o usar maquinaria mientras tomo este medicamento? ¿Puedo conducir o manejar maquinaria después de tomar este medicamento?				
5	¿Cómo sé que mi medicamento inyectable está claro y sin partículas? ¿Cómo preparar y administrar correctamente los medicamentos en forma de solución o suspensión? ¿Cómo debo conservar y cuándo debo desechar este medicamento? ¿Qué es el medicamento y para qué sirve? ¿En qué condiciones debo guardar el medicamento y protegerlo de la luz?				
6	¿Puedo conducir si estoy tomando este medicamento? <i>ERROR_SERVIDOR</i> ¿Cuáles son los posibles efectos secundarios o riesgos que debo conocer antes de tomar este medicamento? ¿Puedo conducir o usar maquinaria mientras estoy tomando este medicamento? Is it safe to drive or operate machinery while taking this medication?				
7	¿Qué riesgo de coágulos sanguíneos tiene este medicamento? ¿Cuáles son los efectos adversos relacionados con la sangre que puede causar este medicamento? ¿Cuáles son los posibles efectos secundarios de este medicamento y qué debo vigilar? ¿Cuál es el riesgo de que este medicamento cause coágulos de sangre (trombosis) o hemorragias, y qué factores pueden aumentarlo? ¿Cómo prevenir la formación de trombos con mi tratamiento?				
8	¿Qué medicamentos no puedo tomar al mismo tiempo que este? <i>ERROR_SERVIDOR</i> ¿Qué debo tener en cuenta al tomar este medicamento con otros, y cuáles son los posibles efectos secundarios? ¿Puedo tomar este medicamento junto con los otros que ya estoy usando? ¿Debo tomar este medicamento con alimentos, después de una comida o en ayunas?				
9	¿Qué contiene este medicamento? <i>ERROR_SERVIDOR</i> Efectos secundarios, composición, cómo se presenta y cómo debo tomar este medicamento? ¿Qué ingredientes o componentes contiene este medicamento? ¿Qué componentes (principio activo y excipientes) tiene este medicamento?				
10	¿Puedo tomar este medicamento? ¿Puedo tomar este medicamento con otros fármacos? ¿Qué debo tener en cuenta antes de tomar este medicamento, incluyendo posibles interacciones con otros fármacos o condiciones médicas preexistentes? ¿Qué debo consultar y tener en cuenta antes de empezar a tomar este medicamento? ¿Puedo tomar este medicamento si estoy tomando otros medicamentos?				
11	¿Cuándo fue la última revisión? ¿Cuándo se revisó por última vez esta información? ¿Cuándo se actualizó por última vez la información de este medicamento? ¿Cuál es la fecha de la última revisión de este prospecto? ¿Cuándo se revisó por última vez este prospecto?				

Se utilizó el prompt refinado utilizado en la síntesis generativa de 12 clústeres.

La evaluación de los resultados mostraron que lejos de descubrir nuevos temas o afinar los existentes, el exceso de datos destruyó el equilibrio logrado en iteraciones anteriores. Como se había identificado en la fase previa, para 5 de los 12 clústeres se generaron preguntas iguales referentes a efectos secundarios. Para un paciente, enfrentarse a un índice con cinco secciones distintas que responden a la misma pregunta (“¿*Qué efectos adversos puedo experimentar?*”) es funcionalmente inútil y cognitivamente agotador.

Además, a pesar de que la instrucción prohibía explícitamente mencionar formatos físicos, la cantidad de 1.000 documentos sobrepasó la capacidad de atención de los modelos. Llama-3 volvió a generar preguntas inservibles para un índice universal, preguntando por un formato físico muy concreto (“...usar la pluma precargada” en el Clúster 7).

Este análisis demostró que, en el procesamiento de lenguaje natural aplicado a textos farmacéuticos, superar cierto volumen de documentos genera un **Rendimiento Marginal Decreciente**. Añadir prospectos masivamente no aporta información clínica nueva, sino que refuerza las plantillas de la AEMPS, añadiendo ruido y dificultando la abstracción de los LLMs.

Por lo tanto, este enfoque quedó descartado y se siguió adelante con los resultados obtenidos en el análisis de 12 clústeres, con el comité de cinco modelos de lenguaje y sobre el dataset base de 500 prospectos.

3.6. Refinamiento y Estandarización Final

Tras finalizar la fase de generación, el sistema disponía de cinco propuestas de “Preguntas Maestras” para cada uno de los 12 clústeres, generadas por el comité de grandes modelos de lenguaje (LLMs). Sin embargo, había preguntas en diferentes clústeres que aún se solapaban. Llegados a este punto, surgió un reto metodológico: ¿cómo se podía elegir la mejor pregunta de forma objetiva?

Para ello se evaluaron las 60 preguntas generadas utilizando dos enfoques diferentes. Esta evaluación se explicará en fases posteriores.

Además, durante esta evaluación se observó un patrón de comportamiento de los LLMs. Muchos de ellos tendían a generar preguntas largas que incluían múltiples cláusulas condicionales (por ejemplo: “¿*Cuáles son los riesgos si tengo asma, problemas de riñón o diabetes?*”).

3.6.1. Experimento de Segmentación Sintáctica

Para la construcción de un índice universal, surgió una nueva hipótesis de investigación: ¿Podrían simplificarse aún más estas preguntas? Se planteó que aislar la “Intención Central” de la pregunta (Núcleo) y eliminar los detalles secundarios (Contexto) podría generar un catálogo visualmente más limpio para el paciente.

Para probar esta hipótesis, se diseñó un experimento de segmentación.

En lugar de dividir las frases a mano, se reutilizó el comité de 5 LLMs, asignándoles el rol de “Analizadores Lingüísticos”.

Mediante una instrucción muy restrictiva, se obligó a los modelos a dividir su propia pregunta en dos variables exactas en formato JSON:

1. **Núcleo:** La intención principal o raíz de la pregunta.
2. **Contexto:** Las cláusulas circunstanciales, síntomas específicos o condiciones añadidas.

La regla estricta fue no reformular ni resumir absolutamente nada, limitándose a extraer literalmente las palabras originales.

Tras evaluar este enfoque a fondo, cuyo proceso y resultados se explicarán en los siguientes capítulos, se concluyó que se usarían las preguntas originales sin modificar como categoría final.

No obstante, la pregunta de cómo elegir la mejor pregunta de entre las cinco de cada clúster seguía sin resolverse. Además, había temas que se solapaban en algunas preguntas de diferentes clústeres y pequeñas alucinaciones.

Para resolver esto, en lugar de realizar una sección manual, se optó por un proceso de refinamiento aplicando una técnica de aprendizaje no supervisado denominado **Meta-Clustering**. El objetivo fue agrupar las propias preguntas generadas por los modelos para encontrar “Macro-Tópicos” naturales y purgar definitivamente cualquier rastro de ruido. El ruido en este contexto son las preguntas que no han conseguido reflejar la misma temática que el resto de preguntas generadas en su mismo clúster y aquellas con alucinaciones (en otros idiomas, o preguntas semánticamente incoherentes con el contenido de los prospectos).

Proyección en el Espacio Latente: El modelo Nomic-MoE

Para que este agrupamiento final fuera lo más preciso posible, se decidió proyectar las preguntas en un nuevo espacio vectorial utilizando el modelo `nomic-embed-text-v2-moe` [17].

Esta elección se dio por dos motivos:

En primer lugar, a diferencia de los modelos estándar, este utiliza una “Mezcla de Expertos”, donde diferentes partes del modelo se especializan en distintos tipos de conceptos, lo que permite una captura de matices semánticos más precisa.

En segundo lugar, siguiendo las mejores prácticas de la arquitectura Nomic, concatenando el prefijo “*search_query:* ” a cada pregunta, se conseguía “avisar” al modelo de que debía procesar el texto buscando su intención de búsqueda profunda, lo que optimizaba la recuperación semántica.

Agrupamiento por Densidad (DBSCAN)

A diferencia del algoritmo K-Means utilizado al principio, para esta fase de unificación se optó por **DBSCAN** (*Density-Based Spatial Clustering of Applications with Noise*). La gran ventaja de este algoritmo es que no requiere que se especifiquen cuántos grupos se quieren obtener; él solo encuentra nubes de significado basadas en la densidad de las preguntas.

Para su configuración, se realizaron varias pruebas de sensibilidad espacial hasta encontrar los parámetros óptimos:

- **Radio de vecindad** ($\epsilon = 0,27$): Se identificó como el punto de equilibrio perfecto. Un radio mayor mezclaba temas distintos, mientras que uno menor fragmentaba demasiado conceptos que eran idénticos. Sin embargo, este parámetro tiene la función de “elector de granularidad”, ya que dependiendo de la especificación que se busque se puede establecer en un valor más alto o más bajo.
- **Consenso mínimo** ($min_samples = 2$): Se estableció que, para que un tema sea considerado válido, al menos dos modelos de lenguaje deben haber generado preguntas similares. Si una pregunta está “sola” en el espacio vectorial, se considera sospechosa de ser ruido.

Detección de Ruido y Visualización Semántica

Una de las capacidades más potentes de DBSCAN es su capacidad para identificar el **Ruido** (**Clúster -1**). En este proyecto, el ruido representa aquellas preguntas que son alucinaciones aisladas, errores gramaticales o rarezas léxicas que no tienen respaldo de otros modelos. Al etiquetarlas como clúster -1, el sistema las elimina automáticamente del dataset final.

Para hacer interpretable este mapa de datos, se utilizó la técnica **t-SNE** (*t-distributed Stochastic Neighbor Embedding*). Esta herramienta permite reducir las cientos de dimensiones de los vectores a solo dos (ejes X e Y), permitiendo visualizar las agrupaciones de forma humana.




Figura 3.3: Mapa Semántico de Tópicos: Unificación de grupos y detección de ruido mediante DBSCAN.

Este proceso permitió que los 12 clústeres originales se reorganizaran en un número menor de Macro-Tópicos sólidos y coherentes. Por ejemplo, todas las variaciones de preguntas sobre “olvido de dosis” que antes estaban dispersas, ahora forman un único grupo semántico unificado. El resultado fue un catálogo de información limpio, sin repeticiones y libre de alucinaciones aisladas.

3.6.2. Análisis de Ruido

Sin embargo, en el desarrollo de sistemas de información clínica, descartar datos automáticamente supone un riesgo de pérdida de conocimiento (*Knowledge Loss*).

Por esta razón, era necesario analizar estas anomalías para determinar si se trataba de verdaderas alucinaciones de los LLMs o si eran preguntas de alto valor semántico que habían quedado aisladas simplemente por tener sintaxis inusual (*Singletons*).

Para evaluar si las preguntas descartadas podían incluirse en el catálogo final se diseñó un algoritmo de “rescate” basado en distancias centroides. Dado que se requería mucha precisión en la medición de similitud entre oraciones, se utilizó el modelo de embeddings **multilingual-e5-large** optimizado para español, implementando su directiva específica (`query:`) para tareas de recuperación.

La arquitectura del algoritmo de rescate se estructuró en tres pasos (Umbralización Adaptativa):

1. **Cálculo de Cohesión Interna:** Para cada Macro-Tópico validado por DBSCAN, se calculó su centroide matemático en el espacio vectorial. Posteriormente, se midió la distancia de todos sus miembros originales contra este centroide para obtener una “Similitud Media”. Este valor actuaba como el identificador de densidad de cada grupo.
2. **Proyección de *Outliers*:** Cada pregunta etiquetada como ruido fue vectorizada y proyectada individualmente contra todos los centroides consolidados. Así se podía comprobar si se parecían semánticamente las frases de cada clúster y las anomalías.

3. **Condición de Rescate:** Se programó una regla determinista en la que un *outlier* solo podía ser reasignado a un Macro-Tópico si su Similitud Coseno superaba el **Umbral Dinámico** específico de dicho grupo. Es decir, la pregunta huérfana debía demostrar matemáticamente ser más afín al núcleo del clúster que el miembro promedio del mismo.

Al ejecutar el algoritmo sobre los Macro-Tópicos (etiquetados del 0 al 7 tras la limpieza de DBSCAN), se obtuvieron los umbrales de cohesión interna representados en la Tabla 3.3.

Tabla 3.3: Similitud media al centroide por Clúster

Clúster	Similitud media al centroide
0	0.9891
1	0.9836
2	0.9158
3	0.9730
4	0.9582
5	0.9739
6	0.9525
7	0.9550

Estos valores confirmaron que las agrupaciones logradas por DBSCAN poseían una cohesión interna extraordinariamente alta y compacta. Al iterar las preguntas consideradas “Ruido” contra estos umbrales dinámicos, el resultado fue que ninguna pregunta superó la condición de rescate.

Para entender visualmente las magnitudes de estas distancias y poder tomar el siguiente paso metodológico se realizó una inspección detallada de las métricas.

En este paso se aplicó una técnica de ingeniería vectorial denominada **Normalización L2** sobre el vector medio de cada clúster antes de calcular la similitud. Cuando un modelo transforma un texto en un vector (*embedding*), genera una especie de “flecha” en el espacio matemático. La **dirección** a la que apunta esa flecha representa la temática o significado del texto, pero su **longitud** (magnitud) a menudo crece dependiendo de cuántas palabras tenga el fragmento original o de cuánto se repitan ciertos términos. La Normalización L2 consiste simplemente en escalar todos los vectores para que midan exactamente lo mismo (longitud igual a 1), manteniendo intacta la dirección a la que apuntan. Al convertir el centroide en un vector de longitud unitaria (módulo = 1), se garantizó que la posterior proyección geométrica dependiera exclusivamente del ángulo entre las frases (Similitud Coseno pura), eliminando cualquier sesgo introducido por el tamaño del modelo de *Embeddings*.

El análisis de la matriz de similitudes de las 12 preguntas descartadas confirmó que se debían mantener estos descartes.

3.6.3. Estandarización final

Tras validar la topología de la información mediante el algoritmo de densidad (DBSCAN) y limpiar las anomalías (ruido), el sistema logró agrupar el conocimiento médico en “Macro-Tópicos” semánticamente puros. Sin embargo, al inspeccionar el interior de cada Macro-Tópico, las preguntas que lo componían seguían presentando variaciones sintácticas o incluso semánticas (como en el clúster de efectos secundarios), ya que provenían de diferentes modelos.

Para conseguir una única pregunta y ofrecer al usuario un índice limpio y sin redundancias, resultó necesario fusionar todas estas variantes en una Categoría Universal definitiva.

Para realizar esta fusión conceptual, se recurrió a la técnica de **Síntesis Generativa** nuevamente. El objetivo fue alimentar a un comité de grandes modelos de lenguaje con todas las preguntas pertenecientes a un mismo Macro-Tópico para que realizaran una abstracción semántica.

Se diseñó un *prompt* (instrucción) estricto bajo los siguientes parámetros técnicos:

1. **Juego de Roles Clínico (*Role-Play*):** Se obligó a los modelos a actuar exclusivamente como pacientes, utilizando la primera persona (ej. “¿Puedo...?”, “¿Qué pasa si...?”) y lenguaje cotidiano.
2. **Restricción de Formato:** Se prohibió absolutamente el uso de preámbulos, saludos, comillas o explicaciones adicionales. El modelo solo podía devolver la cadena de texto de la pregunta pura.
3. **Control Térmico de Inferencia (*Temperatura* = 0.3):** Al reducir el hiperparámetro de la “temperatura” computacional a 0.3, se disminuye la aleatoriedad y la creatividad de la red neuronal, forzando un comportamiento altamente determinista. Esto garantiza que el modelo actúe de forma conservadora, resumiendo las preguntas aportadas y sin riesgo de que invente conceptos ajenos al contexto proporcionado.

El *script* automatizado recorrió los Macro-Tópicos válidos, introdujo las preguntas agrupadas en el contexto de los cinco modelos (*Qwen-3*, *DeepSeek-R1*, *Gemma-3*, *GPT-OSS* y *Nemotron-3*) y les solicitó redactar una nueva y definitiva “Pregunta Maestra” que englobara la intención de todas sus predecesoras sin perder rigor médico.

El resultado de esta iteración fue la generación de una tabla de “Preguntas Candidatas”. Por ejemplo, en el Macro-Tópico referente al olvido de dosis, los modelos unificaron todas las variantes complejas previas en formas muy estandarizadas y limpias, como: “¿Qué hago si olvido o pierdo una dosis?” (*Qwen-3*) o “¿Qué debo hacer si olvido una dosis?” (*DeepSeek-R1*).

Llegados a este punto, el sistema contaba con 5 opciones con alta coherencia semántica para cada Macro-Tópico, lo que hizo necesaria la implementación de una última criba para decidir cuál de ellas se convertiría en el *Gold Standard* definitivo del proyecto.

Para evitar cualquier sesgo humano o de diseño en la elección de la Pregunta Maestra definitiva, se diseñó un proceso de evaluación automatizada. Las 5 preguntas candidatas (sintetizadas por cada uno de los 12 clústeres) compitieron entre sí para demostrar cuál de ellas encapsulaba mejor la “verdad semántica” de las dudas originales del Macro-Tópico. Para ello, se estableció un proceso de validación con las siguientes características:

1. **Motor Vectorial:** Se reutilizó el modelo *multilingual-e5-large*, debido a su altísima calibración para tareas de Similitud Textual Semántica (STS) en español.
2. **Resonancia Intra-Clúster:** En lugar de comparar la candidata contra un centroide teórico (que es un punto imaginario en el espacio), se proyectó cada Pregunta Maestra candidata contra **todas y cada una** de las preguntas originales que conformaban el Macro-Tópico. Tras calcular la distancia contra cada una de ellas, se extrajo la Similitud Coseno Promedio.
3. **Criterio de Victoria:** Este enfoque actúa como un filtro de calidad. Penaliza a los modelos que hayan omitido matices importantes en su resumen y premia a aquellos que hayan logrado una generalización óptima. La candidata con la similitud coseno promedio más alta fue elegida como la ganadora de su clúster.

El algoritmo iteró sobre todos los Macro-Tópicos válidos, vectorizando las candidatas, calculando las matrices de similitud y seleccionando a la ganadora de forma totalmente determinista.

Con todo esto, culminó la arquitectura de procesamiento y síntesis de la información. El sistema partió de más de treinta y dos mil fragmentos clínicos en bruto, los limpió y deduplicó, los agrupó por distancia semántica, generó preguntas universales mediante el uso de LLMs, se analizó el ruido y se

extrajo un catálogo final estandarizado. El resultado fue el Gold Standard del proyecto con categorías universales, redactadas en un lenguaje accesible para el paciente y respaldadas por validación. Una vez obtenido el conjunto de preguntas se podía pasar a la evaluación de las mismas.

Capítulo 4

Evaluación

Esta sección describe el marco metodológico utilizado para evaluar el rendimiento del sistema propuesto y justificar las métricas seleccionadas en relación con los objetivos definidos al inicio del trabajo. El propósito de la evaluación es establecer los criterios cuantitativos y cualitativos empleados para determinar si el catálogo de Preguntas Maestras representa de forma adecuada la información contenida en los prospectos farmacéuticos. En concreto, las métricas de similitud semántica y representatividad textual verifican la calidad de las preguntas generadas asociadas al objetivo O3 (Generación sintética de consultas orientadas al usuario). Los mecanismos automáticos de selección mediante centroides, similitud promedio y métricas Top-k proporcionan una validación cuantitativa del objetivo O4 (Establecimiento de un sistema de evaluación y selección objetiva). Y las evaluaciones comparativas frente a la taxonomía oficial de la AEMPS y las pruebas sobre cientos de prospectos permiten comprobar el cumplimiento del objetivo O5 (Consolidación de un catálogo de referencia estándar) y demostrar si el catálogo universal de Preguntas Maestras consigue actuar como una interfaz semántica más eficiente y accesible para el paciente.

El objetivo principal del sistema consiste en reorganizar la información oficial de los prospectos mediante preguntas formuladas desde la perspectiva del paciente, preservando al mismo tiempo la fidelidad semántica respecto al contenido original publicado por la AEMPS. A partir de este objetivo general, la evaluación se centra en cuatro aspectos:

1. Determinar si las preguntas generadas representan el contenido clínico y administrativo de los prospectos.
2. Comparar la capacidad representacional del nuevo catálogo frente a la estructura regulatoria tradicional de la AEMPS.
3. Analizar la robustez del sistema frente a diferentes medicamentos y contextos terapéuticos.
4. Evaluar si la simplificación lingüística afecta negativamente a la precisión semántica del contenido recuperado.

4.1. Técnicas de Evaluación utilizadas

Para responder a estas cuestiones se diseñó una evaluación basada en técnicas de representación vectorial del lenguaje, similitud semántica y análisis estadístico sobre espacios de *embeddings*. Todas las métricas utilizadas persiguen medir hasta qué punto una Pregunta Maestra consigue actuar como representación semántica del contenido real del prospecto.

4.1.1. Representación Vectorial del Texto

La evaluación se fundamenta en el uso de modelos de *embeddings*, capaces de proyectar fragmentos de texto en un espacio vectorial multidimensional donde la distancia geométrica entre dos vectores refleja su proximidad semántica.

Este enfoque resulta adecuado para el problema planteado porque el objetivo del sistema no consiste en recuperar palabras idénticas, sino en detectar equivalencias conceptuales entre expresiones lingüísticas diferentes. Por ejemplo, una frase del prospecto como:

“Si olvida tomar una dosis, tómela tan pronto como lo recuerde”

puede estar semánticamente relacionada con una pregunta formulada por el paciente como:

“¿Qué hago si se me olvida tomar el medicamento?”

aunque ambas expresiones compartan pocas palabras exactas.

Durante las distintas fases de evaluación se utilizaron dos modelos de representación semántica:

- **paraphrase-multilingual-MiniLM-L12-v2**, empleado en las fases iniciales por su bajo coste computacional y buen rendimiento multilingüe.
- **multilingual-e5-large** [33], utilizado en las evaluaciones finales debido a su mejor comportamiento en tareas de Similitud Textual Semántica (*Semantic Textual Similarity*, STS).

La utilización de modelos entrenados específicamente para STS resulta especialmente relevante en este contexto, ya que la tarea de evaluación depende directamente de medir relaciones de significado entre frases redactadas de forma distinta.

4.1.2. Métrica de Similitud del Coseno

La principal métrica empleada en el estudio fue la Similitud del Coseno. Esta medida calcula el ángulo entre dos vectores dentro del espacio semántico generado por los *embeddings*. Su valor oscila entre -1 y 1, aunque en este contexto práctico las puntuaciones se sitúan normalmente entre 0 y 1.

La elección de esta métrica responde a varias razones:

1. La similitud coseno mide orientación semántica y no longitud textual. Esto permite comparar frases cortas y largas sin penalizar automáticamente los textos más extensos.
2. Es una de las métricas estándar en tareas de recuperación de información, motores de búsqueda semántica y sistemas de recuperación aumentada por generación (*RAG*).
3. Resulta adecuada para espacios de *embeddings*, donde la proximidad angular refleja relaciones conceptuales entre expresiones lingüísticas.
4. Permite cuantificar matemáticamente hasta qué punto una pregunta puede actuar como representación global de múltiples fragmentos clínicos diferentes.

En el contexto de este trabajo, una similitud elevada indica que la Pregunta Maestra conserva adecuadamente la intención semántica del contenido original del prospecto.

4.2. Evaluaciones

Con estas técnicas se llevaron a cabo diversas evaluaciones con propósitos diferentes.

4.2.1. Evaluación Basada en Centroides Semántico

La primera estrategia de evaluación consistió en medir la distancia entre cada Pregunta Maestra y el centroides semántico de su clúster de frases correspondiente.

El centroide representa la media geométrica de todos los vectores pertenecientes a un grupo temático y actúa como una aproximación matemática al contenido central del clúster. Esta metodología permite evaluar si la pregunta generada se sitúa cerca del núcleo semántico del conjunto documental del que procede.

La elección del centroide como referencia se justifica porque: reduce el efecto de frases individuales atípicas; resume la información colectiva del clúster en un único punto vectorial; permite comparar diferentes preguntas utilizando una referencia común y estable; y facilita una selección automatizada sin necesidad de intervención manual.

El procedimiento de evaluación se estructuró en cuatro etapas:

1. Conversión de todos los párrafos y preguntas a vectores semánticos.
2. Cálculo del centroide de cada clúster mediante media aritmética vectorial.
3. Medición de la similitud coseno entre cada pregunta candidata y el centroide correspondiente.
4. Selección de la pregunta con mayor proximidad semántica.

Esta estrategia permite priorizar preguntas representativas del conjunto global de información y no únicamente frases bien redactadas desde un punto de vista lingüístico.

4.2.2. Evaluación Mediante Similitud Promedio Intra-Clúster

Aunque el centroide proporciona una referencia global útil, también presenta limitaciones geométricas derivadas de resumir todo el clúster en un único punto promedio. Para reducir este posible sesgo, se incorporó una segunda estrategia basada en similitud promedio intra-clúster.

En este enfoque, cada Pregunta Maestra se compara individualmente contra todos los fragmentos pertenecientes a su grupo temático. Posteriormente, se calcula la media aritmética de todas las similitudes obtenidas.

Esta métrica fue seleccionada porque: permite evaluar la representatividad global de una pregunta sobre la totalidad del clúster; penalizar preguntas excesivamente específicas o dependientes de frases concretas; detectar si una pregunta logra mantener coherencia semántica con la mayoría del contenido; y reducir el impacto de posibles distorsiones geométricas del centroide.

Desde el punto de vista metodológico, esta evaluación resulta más estricta que la basada únicamente en centroides, ya que obliga a la pregunta candidata a mantener consistencia semántica frente a miles de comparaciones individuales.

4.2.3. Estudio de Ablación Lingüística

Con el objetivo de analizar el impacto del contexto lingüístico en la representatividad semántica, se diseñó un estudio de ablación para las preguntas generadas inicialmente para los 12 clústeres.

En aprendizaje automático, la ablación consiste en eliminar componentes de un sistema para observar cómo afecta su ausencia al rendimiento global. En este caso, la evaluación buscó determinar si las preguntas completas representaban mejor la información clínica que versiones reducidas centradas únicamente en la intención principal.

Para ello, las preguntas generadas fueron segmentadas en dos componentes:

- **Núcleo:** intención principal de la pregunta.

- **Contexto:** condiciones adicionales, síntomas o restricciones clínicas.

Posteriormente, se calcularon métricas de similitud utilizando tanto la pregunta completa como únicamente el núcleo semántico.

La inclusión de esta evaluación se justifica porque uno de los objetivos del proyecto consiste en simplificar la navegación del prospecto sin perder precisión clínica. El estudio de ablación permite medir cuantitativamente si la reducción lingüística implica pérdida de información relevante.

4.2.4. Evaluación Comparativa frente a la Taxonomía Oficial

Uno de los objetivos principales del proyecto consiste en comprobar si una organización basada en preguntas formuladas desde la perspectiva del paciente puede representar mejor el contenido del prospecto que la estructura regulatoria tradicional.

Para ello, se definió como *baseline* la taxonomía oficial de la AEMPS, compuesta por las seis secciones regulatorias obligatorias presentes en todos los prospectos farmacéuticos.

La comparación entre ambos sistemas se realizó utilizando la misma representación vectorial y las mismas métricas de similitud explicadas anteriormente, garantizando así que las diferencias observadas dependieran exclusivamente del tipo de índice utilizado y no del método matemático de evaluación.

Esta comparación permite analizar: qué estructura organiza mejor el contenido clínico real; qué sistema ofrece una representación semántica más cercana al lenguaje utilizado dentro del prospecto; y si las preguntas formuladas desde el punto de vista del paciente mejoran la recuperación de información.

4.2.4.1. Evaluación Multinivel

La evaluación se realizó sobre diferentes niveles de granularidad textual para comprobar la estabilidad del sistema.

Nivel de Frase

Se analizaron frases individuales segmentadas automáticamente desde los prospectos originales. Este nivel permite evaluar relaciones semánticas muy concretas y detectar con precisión qué tipo de información representa mejor cada índice.

Una vez fragmentado el texto del prospecto real (Ibuprofeno) y convertidos todos los elementos a vectores, se midió qué índice representaba mejor la información. Para que el proceso computacional fuera eficiente, se utilizaron operaciones matemáticas de matrices en lugar de analizar las frases una por una mediante bucles.

El diseño de este torneo de evaluación se estructuró de la siguiente manera:

1. **Generación de Matrices:** Se calcularon dos grandes tablas de comparación. La primera midió la distancia geométrica de todas las frases del medicamento contra las 6 Secciones de la AEMPS. La segunda midió esas mismas frases contra el nuevo catálogo de Preguntas Maestras.
2. **Búsqueda del Anclaje Óptimo:** Para cada frase individual del prospecto, el algoritmo buscó su valor máximo de similitud en ambas tablas. El objetivo era responder a la pregunta: *¿Con qué fuerza logra anclarse esta frase a su mejor opción disponible en cada índice?*
3. **Identificación del Ganador:** Finalmente, el sistema registró exactamente qué título oficial o qué Pregunta Maestra había sido elegida por cada frase como su “hogar semántico” ideal.

Además, para comprender el comportamiento estructural de los dos índices se utilizó un gráfico de Estimación de Densidad de Kernel (KDE). Esta herramienta estadística permite visualizar la “probabilidad” de que una frase del prospecto alcance un determinado nivel de similitud semántica en ambos sistemas.

Nivel de Párrafo

Posteriormente, la evaluación se extendió a bloques completos de texto utilizando párrafos y listas extraídos directamente del HTML original de los prospectos. Esta vez el procesamiento consistió en:

1. **Extracción Semántica:** En lugar de dividir el texto por puntos, se utilizaron selectores específicos de HTML (<p> para párrafos y para elementos de lista). Esto permitió capturar bloques de información íntegros, evitando la fragmentación del contexto.
2. **Filtro de Ruido:** Se implementó un umbral de longitud, descartando cualquier bloque con menos de 60 caracteres. Esta medida eliminó títulos cortos, metadatos de formato o índices vacíos, centrando la evaluación puramente en la narrativa clínica.

El objetivo fue comprobar si las Preguntas Maestras eran capaces de actuar como etiquetas precisas para bloques de texto mucho más densos, simulando fielmente la forma en la que un paciente real escanea visualmente un prospecto en busca de respuestas. Este enfoque resulta especialmente importante porque la información médica suele distribuirse en unidades de significado más amplias que una sola oración. Evaluar únicamente frases aisladas podría simplificar artificialmente el problema.

4.2.4.2. Evaluación de Generalización

Una de las críticas más habituales en el desarrollo de sistemas de Procesamiento de Lenguaje Natural es el riesgo de sobreajuste (*overfitting*). Esto ocurre cuando un sistema funciona muy bien para un documento concreto, pero fracasa al intentar aplicarse a otros distintos. Para analizar la capacidad de generalización del sistema, las métricas se aplicaron sobre medicamentos pertenecientes a diferentes áreas terapéuticas.

El objetivo de esta fase consiste en verificar que el catálogo de Preguntas Maestras no depende de un único tipo de prospecto ni de una especialidad clínica concreta.

La evaluación incluye medicamentos de:

- **Analgésicos y Antiinflamatorios:** Ibuprofeno y Aspirina C.
- **Gastrointestinal:** Esomeprazol (protector gástrico).
- **Salud Mental:** Risperidona (antipsicótico).
- **Cardiovascular:** Enalapril (antihipertensivo).
- **Respiratorio:** Ventolín (broncodilatador en formato inhalador).
- **Uso Hospitalario:** Actilyse (medicamento complejo para urgencias).

La inclusión de dominios terapéuticos heterogéneos permite comprobar la robustez semántica del sistema frente a diferentes estilos de redacción médica y distintos niveles de complejidad clínica.

4.2.4.3. Evaluación a Gran Escala

Por otro lado, con el fin de reducir sesgos derivados de muestras pequeñas, se incorporó una evaluación masiva sobre cientos de prospectos extraídos automáticamente desde la API pública de CIMA.

El propósito de esta fase es estudiar la convergencia estadística de las métricas y observar el comportamiento promedio del sistema sobre una distribución amplia de medicamentos reales.

Esta evaluación resulta relevante porque minimiza el riesgo de sobreajuste, reduce el impacto de ejemplos particulares, permite observar tendencias globales del modelo y aporta mayor robustez estadística a las conclusiones posteriores.

Para realizarla, se creó un dataset aleatorio de 500 prospectos:

1. El algoritmo exploró dinámicamente las páginas del listado de medicamentos de la AEMPS, aplicando la función `random.shuffle` para garantizar que la muestra contuviera fármacos de todas las letras del alfabeto, laboratorios y áreas terapéuticas.
2. Una vez obtenidos 500 números de registro válidos (que contuvieran un archivo HTML disponible), el sistema automatizó su descarga, la segmentación del texto en frases y su proyección vectorial.
3. Para cada uno de los 500 prospectos, se calculó el Torneo Semántico entre las Secciones Oficiales y las Preguntas Maestras.

Además, para poder evaluarlo de forma visual se utilizó un histograma de frecuencias con Estimación de Densidad de Kernel.

4.2.4.4. Evaluación Top-k y Cobertura

Finalmente, se incorporó una evaluación basada en métricas Top-k, habituales en sistemas de recuperación de información y motores de búsqueda.

Estas métricas permiten medir no solo si el sistema recupera la categoría correcta, sino también si dicha categoría aparece entre las primeras opciones sugeridas. Para reducir el coste computacional del sistema, se redujo el número de prospectos analizados a 100 documentos aleatorios.

Se utilizaron tres medidas principales:

- **Top-1:** Mide cuántas veces la pregunta elegida por el sistema pertenece exactamente a la misma sección que el texto original de la AEMPS. Es la medida de precisión más estricta.
- **Top-3:** Mide cuántas veces la sección correcta se encuentra entre las tres primeras sugerencias que da el sistema. Un valor alto aquí significa que, aunque el sistema falle en su primera opción, la respuesta sigue estando visible de inmediato para el usuario.
- **Cobertura global:** proporción de fragmentos que son representados con mayor similitud por el nuevo catálogo que por la taxonomía regulatoria tradicional.

La elección de estas métricas responde a un criterio práctico de usabilidad. En un entorno real, un sistema de ayuda médica no necesita únicamente precisión absoluta; también debe facilitar que el usuario encuentre rápidamente la información relevante entre las primeras sugerencias disponibles.

Una vez definidos los métodos de evaluación se procedió a la ejecución y análisis de resultados.

Capítulo 5

Resultados

Tras ejecutar todo el sistema diseñado en la metodología, este generó de forma autónoma el Catálogo de Preguntas Maestras definitivo. A continuación se presentan los resultados de las técnicas y evaluaciones expuestas en el capítulo anterior.

5.1. Resultados de Validación Semántica

Tras generar las preguntas candidatas mediante el comité pentapartito de modelos de lenguaje, antes de refinar las preguntas, se evaluó cuál representaba mejor la información original de cada clúster. Para ello, se aplicaron dos métricas matemáticas independientes: la similitud respecto al centroide del clúster y la similitud promedio frente a todos los fragmentos del grupo.

5.1.1. Similitud respecto al centroide

Para la primera evaluación, el programa iteró sobre los 12 clústeres, calculando las distancias de las propuestas de *Qwen-3*, *DeepSeek-R1*, *Gemma-3*, *GPT-OSS* y *Nemotron-3-Nano* contra sus respectivos centroides. Los resultados fueron los representados en la Figura 5.1.




Figura 5.1: Comparativa de la similitud coseno de cada pregunta al centroide de su clúster.

Tras realizar un análisis visual de los gráficos de barras, los resultados mostraron lo siguiente:

- **DeepSeek-R1 (32B)** fue el modelo más consistente en contenidos clínicos e instructivos, obteniendo la puntuación más alta en 6 de los 12 clústeres (Clústeres 0, 1, 2, 3, 5 y 7), con puntuaciones destacadas de hasta 0.79.
- **GPT-OSS (120B)** se impuso en 3 clústeres (Clústeres 9, 10 y 11), logrando en el Clúster 11 la similitud más alta de todo el experimento (0.88).

- **Gemma-3 (27B)** destacó en 2 clústeres (Clústeres 6 y 8).
- **Qwen-3 (30B)** consiguió resultados competitivos en un único clúster.
- **Nemotron-3-Nano (30B)** no logró superar al resto de modelos en ninguna categoría evaluada.

5.1.2. Similitud Promedio Intra-Clúster

Para elevar aún más el rigor del estudio y descartar cualquier sesgo geométrico, se diseñó una segunda métrica de validación: la **Similitud Coseno Promedio**.

La ejecución de esta métrica no solo confirmó los hallazgos previos, sino que añadió una capa de seguridad adicional al proyecto. Los resultados fueron los siguientes, representados en la Figura 5.2:




Figura 5.2: Comparativa de la similitud coseno de cada pregunta a cada párrafo/frase de su clúster.

Al analizar la nueva tabla de ganadores, se observaron dos fenómenos principales. A pesar del cambio de métrica, la jerarquía de los modelos se mantuvo intacta. **DeepSeek-R1** siguió dominando el bloque clínico (6 clústeres), mientras que **GPT-OSS** continuó siendo el líder en la información administrativa. Esto demuestra que las victorias no eran casualidades del método anterior, sino que reflejan las verdaderas fortalezas de cada arquitectura neuronal. También, se observó que las puntuaciones de similitud bajaron (por ejemplo, el Clúster 0 pasó de 0.79 a 0.57). Este comportamiento es esperado y positivo ya que, al medir contra miles de textos distintos con variaciones de lenguaje, la media siempre es menor que al medir contra un punto centralizado. Lograr una similitud media cercana a 0.50 contra grupos tan grandes demuestra que la pregunta generada abarca una gran cantidad de frases.

El análisis de los resultados, tras aplicar tanto la **Similitud al Centroide** como la **Similitud Promedio Intra-Clúster**, reveló la robustez de la **especialización temática** de los grandes modelos de lenguaje (LLMs). El hecho de que los mismos modelos resultaran ganadores bajo dos lentes matemáticas distintas confirma que sus victorias no son producto de una anomalía geométrica puntual, sino de una capacidad semántica real para interpretar los diferentes contextos del prospecto médico. Además, estos resultados confirmaron la necesidad de utilizar diferentes modelos grandes de lenguaje ya que no hay ninguno que sea dominante en todos los grupos y tareas. No obstante, se reconocieron tres perfiles muy definidos:

- **DeepSeek-R1** su arquitectura de razonamiento lógico le permitió capturar con precisión temas críticos como la posología, el embarazo y la gestión de dosis olvidadas. La convergencia entre ambos métodos de validación en estas categorías fue casi total, demostrando una estabilidad semántica muy alta.

- **GPT-OSS** destacó especialmente en lenguaje técnico y normativo, funcionando mejor en secciones administrativas (Clústeres 9, 10 y 11). En el Clúster 11 alcanzó el pico máximo de representatividad de todo el estudio (0.889 respecto al centroide y 0.829 en similitud promedio).
- **Gemma-3 y Qwen-3** obtuvieron mejores resultados en preguntas concretas relacionadas con riesgos y situaciones específicas del paciente (Clústeres 4, 6 y 8).

5.2. Resultados del Estudio de Ablación Lingüística

Tras analizar las preguntas generadas por los modelos, se observó que muchas incluían contexto adicional además de la intención principal (por ejemplo: “¿Cuáles son los riesgos si tengo asma, problemas de riñón o diabetes?”). Para comprobar si ese contexto realmente aportaba valor semántico, se diseñó un estudio de ablación lingüística, explicado previamente. El experimento comparó dos variantes:

- La pregunta completa generada por el modelo.
- Únicamente el núcleo principal de la pregunta, eliminando el contexto adicional.

Tras segmentar las preguntas, se diseñó un **estudio de ablación**. En ingeniería, la ablación consiste en extirpar una parte de un sistema para comprobar si su ausencia mejora o empeora el rendimiento. El objetivo era medir matemáticamente qué representaba mejor a los prospectos de la AEMPS, la pregunta completa o solo su núcleo.

La ejecución del código y el análisis de los resultados, representados en la figura 5.3, mostraron que eliminar el contexto reducía la representatividad de las preguntas en una media de **-0.0290 puntos de similitud coseno**. Es decir, que la pregunta acortada está geoméricamente más lejos (semánticamente más diferente) de la información de los prospectos que de la pregunta completa.

Este descenso demuestra que las cláusulas adicionales generadas por los modelos no constituyen ruido lingüístico (que empeora la similitud semántica sin aportar nueva información), sino que aportan información semánticamente relevante para la búsqueda. Los síntomas, advertencias y condiciones añadidas forman parte de la carga semántica útil del prospecto médico.

Como consecuencia, el sistema mantuvo las preguntas completas como formato definitivo del catálogo.

5.3. Resultados del análisis de ruido

Cuando se refinaron las preguntas, en el proceso se realizó un análisis de ruido en el que se evaluaba la calidad de los descartes respecto a los clústeres formados. La evaluación confirmó que esos descartes debían mantenerse como tal y se pudieron clasificar esta anomalías en tres categorías predominantes:

1. Grupo Hiper-Específico (*Outliers* Clínicos):

- *Pregunta descartada*: “¿Cómo sé que mi medicamento inyectable está claro y sin partículas?”
- *Análisis*: Su similitud máxima fue de apenas 0.746 (contra el Clúster 5). El algoritmo detectó correctamente que la vía de administración “inyectable” es una particularidad muy específica que no aplica a la inmensa mayoría de los prospectos (que suelen ser medicamentos orales o tópicos). Al descartarla, el sistema protege la universalidad del catálogo general.

2. Grupo de Bajo Dominio:




Figura 5.3: Comparativa entre preguntas completas y preguntas reducidas únicamente al núcleo semántico.

- *Pregunta descartada:* “¿Este medicamento es exento de sodio?”
- *Análisis:* Su similitud máxima cayó a 0.731. Aunque es una pregunta válida para un subgrupo de pacientes (hipertensos), no tuvo la replicación estadística necesaria entre el comité de modelos para ser considerada una “Pregunta Maestra”. Representa un detalle secundario del prospecto, no una categoría principal de información.

3. El Falso Cercano (Anomalía Sintáctica):

- *Pregunta descartada:* “¿Cuáles son las advertencias que deben tener las mujeres embarazadas y en período de lactancia al momento de usar medicamentos?”
- *Análisis:* Su mayor coincidencia fue lógicamente con el clúster de embarazo, alcanzando un 0.820. Sin embargo, el umbral de entrada de ese grupo era de 0.9891. El sistema rechazó esta frase no por su temática, sino porque su redacción excesivamente enrevesada la alejaba de las preguntas directas y estandarizadas del resto del grupo (ej. “¿Puedo tomar este medicamento si estoy embarazada?”).

5.4. Resultados del Torneo Semántico

Una vez elegidas automáticamente las preguntas maestras finales, se procedió a la evaluación final del sistema comparándolo con la taxonomía oficial de los prospectos. Este mostró tres comportamientos relevantes.

1. **Especialización:** Los resultados demostraron que ningún modelo de lenguaje posee una supremacía absoluta en todos los contextos médicos. La elección final resultó en un empate entre **DeepSeek-R1** (3 victorias) y **GPT-OSS** (3 victorias).
 - El modelo GPT-OSS confirmó su dominio en tareas de síntesis burocrática y descriptiva (como los componentes y fechas de revisión).
 - Por su parte, la arquitectura de razonamiento de DeepSeek-R1 se impuso en la síntesis de instrucciones clínicas densas. Fue especialmente notable su victoria en el Clúster 2, donde logró comprimir 14 preguntas originales sobre efectos adversos graves en una única Pregunta Maestra, manteniendo una similitud promedio de 0.849.
2. **Tolerancia a Fallos en Producción:** El registro de ejecución documentó una caída del servidor durante la fase de inferencia del modelo Qwen-3 (arrojando un Error HTTP 500 en los clústeres del 3 al 7). En una arquitectura tradicional dependiente de un solo modelo, esto habría interrumpido la ejecución. Sin embargo, gracias al diseño del comité y a la penalización matemática del juez (asignando 0.0000 de similitud a las respuestas nulas), el sistema absorbió el fallo y seleccionó la mejor alternativa entre los modelos supervivientes sin detener la producción.
3. **Calidad de la Síntesis Clínica:** Las Preguntas Maestras ganadoras alcanzaron métricas de similitud promedio superiores a 0.90 (llegando a picos de 0.97 en los clústeres de posología y embarazo). Estas magnitudes certifican que el tono empático introducido en la instrucción original (“*Actúa como un paciente...*”) no degradó la fidelidad médica de la información original de la AEMPS.

5.5. Resultados de Evaluación sobre Prospectos Reales

Para que la evaluación del sistema fuera rigurosa y generalizable, se evaluó el catálogo de Preguntas Maestras sobre distintos datasets que los usados en la metodología y llevando un proceso gradual de comparación.

Caso de Estudio: Ibuprofeno

La primera validación empírica se realizó utilizando el prospecto real de *Ibuprofeno Normon 600 mg*.

El sistema comparó la capacidad representativa de dos índices distintos para evaluar si cada frase del prospecto está más representada por una Pregunta Maestra o por un título regulatorio:

- Las 6 secciones oficiales de la AEMPS.
- El nuevo catálogo de Preguntas Maestras generado automáticamente.

Al promediar las puntuaciones de todas las frases del prospecto real frente a ambos índices, los resultados globales obtenidos fueron los siguientes:

- Similitud media frente a las secciones oficiales: **0.6730**
- Similitud media frente a las Preguntas Maestras: **0.6920**
- Mejora representacional obtenida: **+2.83 %**

Aunque la diferencia porcentual parece pequeña, en espacios vectoriales de alta dimensionalidad representa una mejora semántica muy significativa. Este resultado positivo confirma la hipótesis planteada para el caso del Ibuprofeno: el índice centrado en el paciente es semánticamente más rico. Es

decir, el nuevo catálogo presenta mayor representatividad semántica respecto el significado real de las advertencias médicas que agruparlas bajo bloques administrativos genéricos.

Para comprender no solo la mejora de la media, sino el comportamiento estructural de este nuevo índice frente al tradicional, se generó un gráfico de Estimación de Densidad de Kernel (KDE) (Figura 5.4). Esto permite visualizar la “probabilidad” de que una frase del prospecto alcance un determinado nivel de similitud semántica en ambos sistemas.




Figura 5.4: Distribución KDE de similitud semántica entre las Secciones Regulatorias y las Preguntas Maestras.

El desplazamiento de la curva de las Preguntas Maestras hacia valores más altos (hacia la derecha) confirma que el nuevo sistema captura mejor el significado real de las frases clínicas presentes en el prospecto. Por otro lado, al observar la curva de las Secciones Regulatorias, destaca un pico muy pronunciado y estrecho. Esta forma geométrica indica que los encabezados oficiales de la AEMPS son excesivamente rígidos. Funcionan muy bien para un grupo pequeño de frases estándar, pero pierden representatividad en otras. Además, la curva del modelo propuesto presenta una base más ancha y suave. Esto ocurre porque las preguntas formuladas desde la perspectiva del paciente son capaces de capturar una variedad mucho más amplia de frases. Al ser semánticamente más flexibles, logran que oraciones que antes quedaban huérfanas o con muy baja similitud, ahora se acerquen a valores altos (entre 0.85 y 0.90), mejorando la cobertura general de todo el documento.

Para entender mejor los resultados, no bastaba con analizar la media global del experimento. Por esta razón se inspeccionaron los valores extremos (outliers). Este análisis permite entender en qué contextos semánticos concretos el nuevo índice de Preguntas Maestras supera al estándar oficial, y en cuáles la estructura de la AEMPS sigue siendo dominante. Para ello, se eliminaron las oraciones de menos de 30 caracteres para evitar sesgos producidos por ruidos de formato o conectores gramaticales vacíos de significado. También, se seleccionaron las cinco frases donde la diferencia matemática a favor de las Preguntas Maestras fue mayor. Esto representa las áreas donde el nuevo modelo demuestra su máxima utilidad clínica. Por último, se aislaron los casos donde el índice de la AEMPS obtuvo una puntuación superior. Esta práctica de ingeniería inversa es útil para identificar posibles “puntos ciegos”.

Para ello, se eliminaron las oraciones de menos de 30 caracteres para evitar sesgos producidos por ruidos de formato o conectores gramaticales vacíos de significado. También, se seleccionaron las cinco frases donde la diferencia a favor de las Preguntas Maestras fue mayor. Esto representa las áreas donde el nuevo modelo demuestra su máxima utilidad clínica. Por último, se aislaron los casos donde el índice de la AEMPS obtuvo una puntuación superior. Esta práctica de ingeniería inversa es fundamental para identificar posibles “puntos ciegos”.

Al analizar cinco casos en los que la similitud era mayor a favor del nuevo modelo, se observó que las Preguntas Maestras superaron al estándar oficial de la AEMPS con diferencias muy notables, alcanzando hasta +0.192 puntos de ventaja. Las secciones de advertencia críticas como las precauciones sobre embarazo o las instrucciones de olvido de dosis, tuvieron una similitud semántica muy cercana a las preguntas generadas. Además, mediante este enfoque se reduce la ambigüedad, por ejemplo, cuando el prospecto indica “*Si olvida tomar su dosis correspondiente, tómela tan pronto como se acuerde*”. Mientras que la taxonomía de la AEMPS esconde esta instrucción bajo el título genérico de “3. *Cómo tomar el medicamento*”, la Pregunta Maestra generada por el sistema (“¿*Qué hago si me olvido de tomar una dosis?*”) logra capturarla con una similitud coseno de **0.906**.

Por el lado contrario, también se analizaron los casos opuestos, en los que las secciones regulatorias obtenían resultados de similitud mayores a los conseguidos por el nuevo modelo. Se observó que estas tuvieron un valor superior cuando evaluaban frases puramente operativas relacionadas con la conservación del envase (como «*Mantener fuera del alcance de los niños*») o el reciclaje (como «*De esta forma, ayudará a proteger el medio ambiente*»). Esto demuestra una realidad, ya que durante el proceso de generación, al ser frases menos numerosas, los LLMs no encontraron densidad suficiente como para crear preguntas con esa temática.

Resultados Evaluación por Párrafos

Posteriormente, la evaluación se elevó desde frases individuales hasta bloques completos de texto y párrafos clínicos con el objetivo de elevar la granularidad del experimento.

Los resultados obtenidos fueron:

- Similitud media frente a las secciones regulatorias: **0.6766**
- Similitud media frente a las Preguntas Maestras: **0.6983**
- Mejora representacional obtenida: **+3.21 %**

Al elevar la granularidad del análisis, los datos revelaron una superioridad semántica del catálogo generado aún más marcada que en el estudio por oraciones sueltas, pasando de un +2.83 % a un +3.21 % de mejora. Este incremento permite extraer tres interpretaciones sobre el rendimiento del modelo.

Primero, se observa un ajuste conceptual superior. El hecho de que las nuevas preguntas obtengan una mayor similitud al enfrentarse a textos largos demuestra que logran capturar el núcleo de una idea compleja con mucha más eficacia que las categorías oficiales. También, estos datos evidencian la superación del estándar burocrático actual ya que la taxonomía oficial de la AEMPS se queda corta al intentar etiquetar párrafos densos. Al lograr reducir la distancia matemática entre el nuevo índice y el texto real, se garantiza que, a nivel de experiencia de usuario, el paciente encontrará la información clínica de forma mucho más rápida e intuitiva. Además, el sistema demuestra robustez ante la densidad del texto. A nivel matemático, cuantas más palabras hay en un bloque, los modelos de vectorización (*embeddings*) tienden a diluir la puntuación de similitud. Sin embargo, el nuevo catálogo no solo mantuvo su ventaja en estos escenarios desfavorables, sino que consiguió aumentarla. Esto prueba que las Preguntas Maestras generadas por el comité de modelos de lenguaje funcionan como representaciones universales del conocimiento farmacéutico.

Resultados Evaluación Multiterapéutica

Para comprobar la capacidad de generalización del sistema, se evaluaron siete medicamentos pertenecientes a áreas terapéuticas distintas.

Los resultados obtenidos confirmaron que el nuevo índice en el **85.7 % de los casos** (6 de 7 fármacos) conseguía mejores valores de similitud, logrando una mejora promedio global del **+1.32 %** en todo el conjunto de datos como vemos en la Tabla 5.1.

Resultados Macro-Evaluación (N=500)

Tabla 5.1: Resultados de la Evaluación Multiterapéutica

Medicamento	Especialidad	Media AEMPS	Media Preguntas	Mejora (%)
Aspirina C	Analgésico	0.6775	0.6990	+ 3.17 %
Ibuprofeno	Analgésico/AINE	0.6729	0.6919	+ 2.82 %
Esomeprazol	Gastrointestinal	0.6641	0.6806	+ 2.48 %
Enalapril	Cardiovascular	0.6677	0.6793	+ 1.74 %
Risperidona	Salud Mental	0.6893	0.6978	+ 1.23 %
Ventolín	Respiratorio	0.6654	0.6692	+ 0.56 %
Actilyse	Fibrinolítico (Hosp.)	0.6773	0.6586	- 2.76 %




Figura 5.5: Comparativa de representatividad media por medicamento.

La validación final se realizó utilizando 500 prospectos reales obtenidos automáticamente desde la API pública de CIMA.

Los resultados fueron los siguientes:

Tabla 5.2: Resultados Consolidados de la Macro-Evaluación ($N = 500$)

Métrica de Evaluación	Valor
Similitud Media Regulatoria (Baseline)	0.6745
Similitud Media Preguntas Maestras	0.6841
Mejora Neta Promedio	+1.42 %

La Ley de los Grandes Números es un teorema de la probabilidad y la estadística que dice que si repites un experimento aleatorio muchísimas veces, el resultado promedio empírico se acercará al valor teórico esperado. Al aplicar esta ley, se observa que la mejora matemática se estabiliza en +1.42 %. Aunque numéricamente es una cifra más ajustada que en las pruebas con los analgésicos más comunes, tiene gran valor científico. Demuestra que, independientemente de si el fármaco evaluado es un colirio, una vacuna, un tratamiento oncológico o una crema tópica, el sistema de Preguntas Maestras ofrece siempre una representación semántica semánticamente más representativa comparado con las secciones actuales.




Figura 5.6: Distribución de la mejora porcentual en la muestra masiva de 500 prospectos.

La distribución mostró un sesgo positivo hacia la derecha del eje, a la derecha del 0 % o línea de empate, indicando que la mayoría de los medicamentos obtuvieron mejores resultados utilizando el catálogo de Preguntas Maestras. Si bien el histograma registra picos de mejora superiores al 5 %, la media global del conjunto logra converger de manera firme en un +1.42 %. Por el contrario, el gráfico muestra algunos casos que caen en el área negativa. No obstante, estos valores atípicos representan una minoría estadística muy aislada que, siguiendo la tendencia descubierta en fases previas, corresponde exclusivamente a frases de fármacos de uso ultra-especializado o frases sobre conservación.

Resultados Evaluación Top-k

La auditoría final procesó 100 prospectos reales y un total de 6.626 párrafos clínicos.

Las métricas globales obtenidas fueron:

- Exactitud Top-1: **39.12 %**
- Exactitud Top-3: **69.83 %**
- Cobertura Global: **69.42 %**

Estos resultados indican que, en aproximadamente 7 de cada 10 casos, la información correcta aparecía entre las tres primeras sugerencias ofrecidas por el sistema. Además, el sistema logró una **Cobertura Global del 69.42 %**, lo que significa que, frente a un texto médico cualquiera, casi en el 70 % de los casos las frases se identifican mejor con el lenguaje propuesto que con el oficial.

Tabla 5.3: Tasa de Victoria (*Win-Rate*) por Sección Oficial

Sección Regulatoria (AEMPS)	Win-Rate (%)	Nº Párrafos
3. Cómo tomar el medicamento	79.56 %	1.424
2. Antes de empezar a tomarlo	78.84 %	2.018
4. Posibles efectos adversos	73.33 %	1.185
6. Contenido del envase	52.79 %	1.381
1. Qué es y para qué sirve	51.40 %	393
5. Conservación del medicamento	33.78 %	225

El desglose de los resultados presentes en la Tabla 5.3 revela hallazgos interesantes. Los mejores resultados aparecieron en las secciones más importantes para el paciente: administración, efectos adversos y precauciones clínicas. En apartados como «*Cómo tomar*» (con un 79.56 %) o «*Posibles efectos adversos*» (que alcanza un 73.33 %), el sistema propuesto se muestra ampliamente con mayor representatividad semántica que la taxonomía regulatoria.

Por el contrario, las únicas áreas donde la estructura tradicional mantuvo ventaja fueron las relacionadas con conservación, logística y reciclaje del medicamento («*Conservación del medicamento*», 33.78 %), lo que confirma que el sistema muestra un mejor ajuste en la información clínica relevante para la toma de decisiones del paciente.

5.6. Objetivos Logrados

Tras finalizar el desarrollo de la arquitectura algorítmica y ejecutar las métricas de evaluación sobre prospectos reales, se procedió a verificar el grado de cumplimiento de los objetivos definidos al inicio del proyecto.

5.6.1. Objetivos específicos

El sistema desarrollado logró satisfacer de forma satisfactoria los cinco objetivos específicos planteados.

O1. Extracción y depuración de datos

Se implementó un *pipeline* automatizado conectado directamente a la API REST de CIMA. El sistema consiguió descargar, limpiar y segmentar prospectos médicos en formato HTML de forma completamente autónoma. Además, las técnicas de filtrado y deduplicación semántica permitieron eliminar gran parte del ruido burocrático presente en los documentos originales.

O2. Estructuración y descubrimiento de temas

La aplicación secuencial de algoritmos de aprendizaje no supervisado permitió segmentar automáticamente los prospectos en grupos temáticos coherentes. La combinación de *K-Means* y DBSCAN consiguió aislar tanto los grandes bloques semánticos como las anomalías textuales de las preguntas sin necesidad de etiquetado manual.

O3. Síntesis mediante comité de modelos

El proyecto logró orquestar un sistema basado en múltiples Modelos Grandes de Lenguaje (*Ensemble*). Modelos como Qwen-3, DeepSeek-R1, Gemma-3, GPT-OSS y Nemotron-3 colaboraron en la generación de preguntas clínicas centradas en el paciente. Además, el diseño estricto de instrucciones con técnicas de Prompt Engineering y el control de temperatura minimizaron la aparición de alucinaciones o contenido inventado.

O4. Validación matemática imparcial

Se desarrolló un sistema de evaluación completamente algorítmico basado en similitud coseno y embeddings semánticos. El motor `multilingual-e5-large` permitió comparar matemáticamente miles de fragmentos clínicos y seleccionar automáticamente las preguntas más representativas. El sistema también demostró resiliencia ante errores de inferencia y caídas de servidores externos.

O5. Consolidación de un catálogo estándar

El proyecto consiguió construir un catálogo universal de Preguntas Maestras capaz de superar sistemáticamente la estructura oficial de la AEMPS. La macro-evaluación sobre 500 medicamentos mostró una mejora promedio estable del **+1.42 %** y una cobertura cercana al **70 %** en métricas Top-3.

5.6.2. Objetivo general

La consecución de todos los objetivos específicos valida el cumplimiento del objetivo principal del proyecto.

Se diseñó, implementó y validó con éxito un sistema capaz de transformar la estructura técnica de los prospectos farmacéuticos en un índice universal orientado al paciente. Las evaluaciones realizadas demostraron que el sistema no funciona únicamente como una prueba de concepto experimental, sino como una arquitectura robusta, escalable y con mayor representatividad semántica respecto al modelo tradicional basado exclusivamente en categorías oficiales.

Además, los resultados obtenidos sobre grandes volúmenes de datos confirman la capacidad del sistema para generalizar correctamente a distintos medicamentos, especialidades terapéuticas y estilos de redacción clínica.

5.7. Discusión de Limitaciones y Problemas Encontrados

Durante el desarrollo del proyecto surgieron diferentes limitaciones técnicas y metodológicas que condicionaron parte del comportamiento del sistema. Analizar estos problemas resulta importante para comprender tanto las fortalezas como las limitaciones reales de la arquitectura propuesta.

Uno de los principales problemas fue la elevada demanda computacional de los Modelos Grandes de Lenguaje utilizados durante la fase de síntesis. La ejecución local de modelos con millones de parámetros provocaba tiempos de inferencia excesivos y un consumo muy elevado de memoria RAM y VRAM. En determinadas pruebas, algunos modelos superaban fácilmente la capacidad disponible del hardware local, obligando a reducir el tamaño de lote (*batch size*), simplificar inferencias o limitar el número de iteraciones del sistema. Esto afectaba directamente a la velocidad experimental y dificultaba realizar pruebas masivas de manera continua. Como consecuencia, gran parte de la inferencia tuvo que externalizarse a servidores remotos. Esta dependencia introdujo nuevos problemas relacionados con

estabilidad y disponibilidad. Durante varias ejecuciones se produjeron errores HTTP 500 debido a la saturación de los servidores, lo que impedía trabajar con agilidad y generaba un cuello de botella.

Aunque la arquitectura basada en comité de modelos permitió mitigar parcialmente este problema, el sistema continúa dependiendo de recursos computacionales externos para poder escalar correctamente. Cuando uno de los modelos fallaba, el algoritmo asignaba automáticamente una puntuación nula y continuaba la evaluación con el resto del comité, evitando así la interrupción completa del flujo de trabajo. Esta tolerancia a fallos mejoró significativamente la robustez práctica del sistema. Sin embargo, esta dependencia de infraestructura remota sigue siendo una limitación importante para la reproducibilidad total del proyecto. Los resultados pueden variar ligeramente dependiendo de la disponibilidad del servidor, de la versión concreta del modelo desplegado o incluso de cambios internos realizados por los proveedores de inferencia.

Otra dificultad importante apareció durante la generación de preguntas clínicas. A pesar del diseño cuidadoso de los *prompts*, algunos modelos mostraban comportamientos impredecibles: generación de contenido inventado, pérdida del contexto clínico, cambios inesperados de idioma, respuestas excesivamente genéricas, desviaciones semánticas respecto al texto original. Este comportamiento fue especialmente frecuente en determinados modelos de la familia Llama, que mostraron una alta tasa de alucinación al enfrentarse a tareas de síntesis clínica en español. Aunque estos modelos funcionan adecuadamente en tareas generales conversacionales, demostraron menor precisión cuando debían mantener fidelidad médica.

Para reducir este problema se aplicaron varias estrategias, entre las que destacan el filtrado manual de modelos poco estables sustituyéndolos por modelos más adecuados para la tarea, la reducción de temperatura de inferencia para reducir la creatividad de los LLMs, el refinamiento iterativo mediante clústeres semánticos y el uso de un segundo proceso de síntesis para consolidar preguntas finales. Aunque estas técnicas mejoraron considerablemente la estabilidad, las alucinaciones continúan siendo una limitación estructural inherente a los modelos generativos actuales. Esto implica que cualquier aplicación clínica real requeriría mecanismos adicionales de validación y supervisión humana antes de utilizar las respuestas en entornos sanitarios sensibles.

Por otro lado, la API de CIMA proporciona información oficial y muy extensa, pero los documentos descargados presentan una gran heterogeneidad estructural. Muchos prospectos contienen restos de etiquetas HTML, saltos de formato inconsistentes, fragmentos duplicados y metadatos administrativos y contenido no clínico. Todo este ruido afectaba directamente a la calidad de los embeddings y dificultaba el agrupamiento semántico. Los modelos de vectorización son especialmente sensibles a pequeñas alteraciones sintácticas, por lo que la presencia de ruido degradaba la representación matemática del texto. Para solucionarlo se desarrolló un proceso intensivo de limpieza basado en expresiones regulares, segmentación estructural y filtrado por longitud mínima. Aunque este preprocesamiento mejoró notablemente la calidad final, sigue existiendo una dependencia fuerte de la calidad del documento original publicado por la AEMPS.

Otra de las limitaciones se encontró en la fase de clustering. Algoritmos como *K-Means* dependen directamente del número de clústeres elegido (K), mientras que DBSCAN es muy sensible a parámetros de densidad y distancia. Esto provocó la aparición de clústeres redundantes, fragmentación excesiva de algunos temas, colapso semántico entre categorías similares y pérdida de información minoritaria. Las secciones relacionadas con conservación, reciclaje o logística del medicamento fueron problemáticas debido a su baja densidad semántica y reducido volumen textual. En muchos casos, estas categorías terminaban absorbidas por otros clústeres más grandes o directamente descartadas como ruido. Esta limitación afecta directamente a la capacidad de generalización completa del sistema, ya que determinadas áreas administrativas siguen estando infrarrepresentadas frente a los bloques clínicos más frecuentes. Aunque esta decisión puede considerarse razonable desde una perspectiva centrada en el paciente, limita la capacidad del sistema para actuar como un sustituto completo de la taxonomía oficial de la AEMPS. Además, el clustering semántico trabaja sobre espacios vectoriales de alta dimensionalidad. En este tipo de espacios aparece frecuentemente el fenómeno conocido como “maldición de la dimensionalidad”, donde las distancias entre vectores tienden a volverse menos discriminativas. Esto puede provocar agrupamientos artificiales o asociaciones semánticas débiles entre textos clínicamente distintos.

También se observó que, aunque la macro-evaluación sobre 500 prospectos mostró resultados sólidos y estables, el sistema presenta todavía ciertas limitaciones de generalización. La mejora observada converge en torno al +1.42 %, lo que demuestra estabilidad estadística, pero también indica que existen numerosos casos donde la taxonomía oficial sigue siendo competitiva o incluso superior. Esto indica que el sistema todavía depende parcialmente de patrones lingüísticos frecuentes y puede perder capacidad representativa cuando el lenguaje médico se vuelve excesivamente específico o por baja densidad.

Además, el sistema ha sido entrenado y evaluado exclusivamente sobre documentación farmacéutica española procedente de la AEMPS. No puede garantizarse que el mismo comportamiento se mantenga en otros entornos regulatorios, otros idiomas o documentación clínica distinta.

Adicionalmente existe una limitación conceptual importante: la similitud semántica no equivale necesariamente a comprensión clínica real. Aunque los embeddings permiten medir proximidad matemática entre textos, esto no garantiza automáticamente que un paciente comprenda mejor la información. En un prospecto, instrucciones como “tomar si presenta fiebre” y “no tomar si presenta fiebre” comparten casi todo su vocabulario y estructura, por lo que el modelo de embeddings proyecta ambas frases muy juntas y les otorga una similitud altísima, a pesar de que clínicamente significan exactamente lo opuesto. Por tanto, futuras líneas de investigación deberían incorporar estudios de validación con usuarios reales, evaluaciones cognitivas y métricas de comprensión lectora clínica para complementar las métricas vectoriales utilizadas en este trabajo.

En conjunto, todas estas limitaciones reflejan que el sistema propuesto debe interpretarse como una arquitectura experimental prometedora, pero no como una solución clínica definitiva completamente autónoma. Aun así, los resultados obtenidos muestran que, incluso bajo condiciones imperfectas, el modelo logra mejorar sistemáticamente la representatividad semántica de los prospectos respecto al estándar oficial actual. Esto demuestra que la aproximación basada en preguntas centradas en el paciente constituye una línea de investigación válida.

Sin embargo, las limitaciones observadas permiten extraer varias implicaciones importantes para futuras líneas de investigación.

En primer lugar, el rendimiento del sistema no depende únicamente de los modelos de lenguaje, sino también de la calidad estructural del texto original y de las decisiones tomadas durante el preprocesamiento y clustering.

En segundo lugar, la especialización temática detectada entre modelos confirma que los sistemas basados en *Ensemble* resultan más robustos que las arquitecturas basadas en un único LLM.

Finalmente, los resultados muestran que existe un equilibrio delicado entre simplificación lingüística y pérdida de precisión clínica. Aunque las preguntas centradas en el paciente mejoran la accesibilidad semántica, una simplificación excesiva puede reducir la fidelidad médica del contenido.

En definitiva, superar todos estos obstáculos ha sido una de las partes más enriquecedoras del proyecto. Tener que lidiar con servidores inestables, modelos impredecibles y estructuras heterogéneas obligó a desarrollar un sistema mucho más robusto y cercano a las condiciones reales de producción. A pesar de todas estas limitaciones, el sistema demostró un comportamiento estable y positivo en escenarios reales de evaluación.

Los problemas encontrados no invalidan la arquitectura propuesta, sino que reflejan las dificultades del procesamiento automático de lenguaje médico mediante Inteligencia Artificial generativa.

Capítulo 6

Conclusiones y trabajos futuros

6.1. Conclusiones

Este proyecto ha estudiado cómo utilizar técnicas de Ciencia de Datos e Inteligencia Artificial para reorganizar la información de los prospectos farmacéuticos desde una perspectiva más cercana al paciente. El objetivo principal ha sido desarrollar un sistema capaz de transformar la estructura tradicional de los prospectos oficiales en un índice basado en preguntas reales que una persona podría hacerse al tomar un medicamento, manteniendo siempre el rigor clínico del contenido original.

Para ello, el trabajo partió de los prospectos obtenidos desde la API oficial de CIMA y de la organización regulatoria establecida por la AEMPS. A medida que se fue analizando el comportamiento de esta estructura tradicional, se observó que muchas de sus categorías resultaban demasiado rígidas, genéricas y poco intuitivas para un usuario no especializado. Aunque la organización oficial cumple correctamente su función administrativa, no siempre facilita que el paciente encuentre de forma rápida la información que realmente necesita en situaciones cotidianas.

Con el propósito de mejorar esta limitación, se diseñó una arquitectura basada en representación semántica del lenguaje, clustering y modelos generativos. En una primera fase se desarrolló un proceso automático de limpieza y normalización de datos para eliminar ruido procedente del HTML original de los prospectos. Posteriormente, se utilizó el algoritmo K-Means para agrupar frases según su similitud semántica y descubrir los grandes bloques temáticos presentes en la información médica. Luego, se empleó un comité de Modelos Grandes de Lenguaje para sintetizar cada grupo y generar preguntas formuladas desde el punto de vista del paciente. Finalmente, se volvió a utilizar el comité para refinar las preguntas finales.

Los resultados obtenidos muestran que este enfoque consigue mejorar de forma objetiva la representación semántica de los prospectos farmacéuticos. Las evaluaciones realizadas mediante embeddings y similitud del coseno reflejan que el catálogo de Preguntas Maestras logra actuar como un índice más preciso y cercano al contenido real de los prospectos que la taxonomía oficial tradicional, lo que facilita la búsqueda de información por los pacientes.

Además, las pruebas realizadas sobre distintos medicamentos y especialidades terapéuticas demuestran que el sistema mantiene un comportamiento relativamente estable incluso en contextos clínicos diferentes. Las mejoras fueron especialmente visibles en las secciones más importantes para la seguridad del paciente, como instrucciones de administración, olvidos de dosis, efectos adversos o contraindicaciones. Esto indica que las preguntas generadas consiguen acercar la información médica al usuario de una forma más natural y accesible.

Durante el desarrollo también se comprobó que ningún modelo generativo ofrecía resultados “perfectos” de manera individual. Algunos modelos producían preguntas muy precisas pero presentaban una mayor tendencia a generar alucinaciones o cambios inesperados de idioma, mientras que otros resultaban más estables, aunque menos concretos. La utilización de una arquitectura basada en comité permitió equilibrar estas diferencias y mejorar la robustez global del sistema. En lugar de depender completamente de un único modelo, el sistema compara múltiples propuestas y selecciona automáticamente las preguntas más representativas desde el punto de vista semántico.

A pesar de los resultados positivos, el proyecto también presenta limitaciones importantes. El sistema sigue dependiendo parcialmente de infraestructura externa para ejecutar determinados modelos,

lo que afecta a la reproducibilidad y estabilidad de algunas evaluaciones. Además, ciertos bloques de información con baja densidad semántica, como las secciones relacionadas con conservación o reciclaje del medicamento, continúan siendo difíciles de representar mediante clustering. También se observó sensibilidad a determinados parámetros de agrupamiento, especialmente en algoritmos como K-Means y DBSCAN, lo que puede provocar fragmentación temática o aparición de clústeres redundantes.

Otra limitación importante es que los Modelos Grandes de Lenguaje continúan presentando problemas en la generación automática de texto, como alucinaciones, pérdida parcial de contexto o desviaciones semánticas. Aunque las estrategias de refinamiento y evaluación matemática reducen considerablemente estos errores, todavía no es posible garantizar una fiabilidad absoluta en todos los casos. Por este motivo, este tipo de herramientas deben entenderse como sistemas de apoyo y organización de información, y no como sustitutos del criterio médico profesional.

En conjunto, los resultados obtenidos muestran que es posible utilizar técnicas modernas de representación semántica e Inteligencia Artificial Generativa para construir sistemas de acceso a información médica más intuitivos y centrados en las necesidades reales del paciente. El catálogo de Preguntas Maestras desarrollado en este trabajo no solo mejora la organización conceptual de los prospectos farmacéuticos, sino que también demuestra el potencial de combinar modelos generativos, análisis matemático y procesamiento del lenguaje natural para resolver problemas reales de accesibilidad dentro del ámbito sanitario.

6.2. Impacto social y medioambiental

El desarrollo de este proyecto no solo tiene un impacto tecnológico sino que también tiene un impacto directo en la sociedad y se alinea fuertemente con la Agenda 2030 de las Naciones Unidas y los Objetivos de Desarrollo Sostenible (ODS). En el ámbito social, el sistema aporta un gran valor al ODS 3 (Salud y bienestar). Al transformar los textos técnicos en preguntas claras, se consigue que cualquier persona pueda encontrar de forma más sencilla a la información de su medicación. Encontrar rápido una respuesta ayuda a prevenir errores médicos, mejora el seguimiento de los tratamientos y da mucha más tranquilidad a los pacientes. Además, esto apoya el ODS 10 (Reducción de las desigualdades), ya que rompe la barrera del lenguaje complejo y hace que la información de salud sea accesible para personas mayores o con menor nivel educativo.

Por otro lado, es necesario ser honestos con el impacto medioambiental del proyecto. Es una realidad que el uso de servidores y grandes modelos de lenguaje consume mucha energía, lo que genera una huella de carbono importante. Para mitigar este problema, el código del sistema se ha diseñado para ser eficiente. Al usar algoritmos previos para limpiar y agrupar los datos, se evita que los modelos de lenguaje procesen texto inútil y gasten recursos de más.

A pesar de este coste energético, a largo plazo el proyecto contribuye ligeramente al ODS 12 (Producción y consumo responsables). Lograr un formato digital seguro, ordenado y fácil de usar es el paso técnico necesario para poder modernizar el sector. Si los pacientes confían en herramientas digitales como esta, la industria farmacéutica podrá reducir o eliminar la necesidad de imprimir millones de prospectos en papel cada año, logrando un ahorro ecológico gigantesco en la fabricación de medicamentos.



Figura 6.1: ODS relacionados con este PFG.

6.3. Líneas futuras

Los resultados obtenidos abren diferentes posibilidades de ampliación y mejora para futuros trabajos.

Una de las líneas más interesantes consiste en integrar esta arquitectura dentro de sistemas conversacionales basados en RAG (*Retrieval-Augmented Generation*). Para ello, los textos médicos procesados y sus representaciones vectoriales podrían almacenarse en una base de datos semántica. De esta forma, un asistente virtual sería capaz de recuperar únicamente información validada procedente de los prospectos oficiales antes de generar cualquier respuesta, reduciendo significativamente el riesgo de alucinaciones o respuestas inventadas.

Otra posible evolución del proyecto sería el entrenamiento de modelos especializados en medicina en español mediante técnicas de ajuste fino (*fine-tuning*). Utilizando métodos eficientes como LoRA, sería posible adaptar modelos de código abierto a partir de ejemplos clínicos extraídos directamente de la AEMPS. Esto permitiría desarrollar sistemas más pequeños, especializados y ejecutables en infraestructura local, mejorando tanto la privacidad como la independencia respecto a servicios externos.

Debido a la limitación de las métricas vectoriales frente a las negaciones médicas, también sería interesante incorporar mecanismos de validación humana mediante profesionales sanitarios. La participación de médicos, farmacéuticos o especialistas permitiría evaluar clínicamente la calidad de las Preguntas Maestras generadas y construir conjuntos de datos validados para futuras investigaciones supervisadas. Además, se podría contar con pacientes para probar la eficacia del sistema y verificar si realmente se facilita el acceso a la información.

Finalmente, otra línea de trabajo consistiría en personalizar automáticamente la información mostrada según las características del usuario. Para construir esta función, se añadiría una nueva capa de instrucciones o prompts del sistema en el código. La aplicación recogería variables básicas del perfil del usuario, como su idioma o su edad. Al recuperar la información médica del prospecto, se obligaría al modelo de lenguaje a aplicar un filtro automático de reescritura antes de mostrar la pantalla final. Si el paciente es un niño, el sistema cambiaría el vocabulario técnico por uno más sencillo apoyándose en métricas de legibilidad. Si es un turista, traduciría el texto en tiempo real, pero manteniendo siempre el rigor del documento original intacto.

En conjunto, estas líneas futuras muestran que el trabajo presentado no solo constituye una solución técnica para estructurar y simplificar información farmacéutica, sino también una base sólida sobre la que desarrollar sistemas médicos inteligentes más accesibles, fiables y adaptados al usuario. La combinación de modelos de lenguaje, recuperación semántica y validación profesional abre la puerta a asistentes capaces de ofrecer información sanitaria comprensible sin perder el rigor clínico.

Bibliografía

- [1] Agencia Española de Medicamentos y Productos Sanitarios (AEMPS), “Centro de información de medicamentos (cima),” <https://cima.aemps.es/cima/publico/home.html>.
- [2] L. O’Sullivan, P. Sukumar, R. Crowley, E. McAuliffe, and P. Doran, “Readability and understandability of clinical research patient information leaflets and consent forms in ireland and the uk: a retrospective quantitative analysis,” *BMJ Open*, vol. 10, no. 9, p. e037994, 2020. [Online]. Available: <https://bmjopen.bmj.com/content/10/9/e037994.abstract>
- [3] P. Nitti, “Italian medical language: A corpus-based study on patient information leaflets,” *Forum Italicum*, 2025. [Online]. Available: <https://journals.sagepub.com/doi/abs/10.1177/00145858241309335>
- [4] W. K. Gyasi, “Linguistic complexity of patient information leaflets: A coh-metrix analysis,” *Athens Journal of Health and Medical Sciences*, vol. 10, no. 4, pp. 243–260, 2023. [Online]. Available: <https://www.athensjournals.gr/health/2023-10-4-4-Gyasi.pdf>
- [5] A. Hill-Madsen, “Semantic density and gravity in lay-oriented medical knowledge communication ii: The case of patient information leaflets,” *Nordic Journal of English Studies*, vol. 24, no. 1, pp. 41–74, 2025. [Online]. Available: <https://publicera.kb.se/njes/article/view/41116>
- [6] M. M. van Beusekom, A. M. Land-Zandstra, M. J. Bos, J. M. van den Broek, and H.-J. Guchelaar, “Low literacy and written drug information: information-seeking, leaflet evaluation and preferences, and roles for images,” *International Journal of Clinical Pharmacy*, vol. 38, no. 6, pp. 1372–1379, 2016. [Online]. Available: <https://link.springer.com/article/10.1007/s11096-016-0376-4>
- [7] J. Sweller, “Cognitive load during problem solving: Effects on learning,” *Cognitive science*, vol. 12, no. 2, pp. 257–285, 1988. [Online]. Available: [https://doi.org/10.1016/0364-0213\(88\)90023-7](https://doi.org/10.1016/0364-0213(88)90023-7)
- [8] H. Pander Maat and L. Lentz, “Improving the usability of patient information leaflets,” *Patient Education and Counseling*, vol. 80, no. 1, pp. 113–119, 2010. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0738399109004467>
- [9] X. Pan, E. Kim, J. Zamora, M. Hata, A. Wooley, R. Devraj, H. P. Gogineni, and A. V. Law, “The comprehension, cosmetics, convenience, content, and credibility of infographic patient information leaflets (ipils) compared to existing pills (epils),” *Healthcare*, vol. 13, no. 11, p. 1227, 2025. [Online]. Available: <https://doi.org/10.3390/healthcare13111227>
- [10] D. Stephan, A. S. Bertsch, S. Schumacher, B. Puladi, M. Burwinkel, B. Al-Nawas, P. W. Kämmerer, and D. G. Thiem, “Improving patient communication by simplifying ai-generated dental radiology reports with chatgpt: comparative study,” *Journal of Medical Internet Research*, vol. 27, p. e73337, 2025.
- [11] A. Pal, T. Wangmo, T. Bharadia, M. Ahmed-Richards, M. B. Bhandari, R. Kachhadiya, S. S. Allemann, and B. S. Elger, “Generative ai/lms for plain language medical information for patients, caregivers and general public: Opportunities, risks and ethics,” *Patient preference and adherence*, pp. 2227–2249, 2025.
- [12] A. Miftaroski, R. Zowalla, M. Wiesner, and M. Pobiruchin, “Leveraging large language models to improve the readability of german online medical texts: Evaluation study,” *JMIR AI*, vol. 5, p. e77149, 2026.
- [13] D. M. Blei, A. Y. Ng, and M. I. Jordan, “Latent dirichlet allocation,” *Journal of machine Learning research*, vol. 3, no. Jan, pp. 993–1022, 2003.
- [14] A. M. Jalil, I. Hafidi, L. Alami, and K. Ensa, “Comparative study of clustering algorithms in text mining context,” 2016.

- [15] M. Ester, H.-P. Kriegel, J. Sander, X. Xu *et al.*, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *kdd*, vol. 96, no. 34, 1996, pp. 226–231.
- [16] N. Reimers and I. Gurevych, “Sentence-bert: Sentence embeddings using siamese bert-networks,” in *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)*, 2019, pp. 3982–3992.
- [17] Z. Nussbaum, J. X. Morris, B. Duderstadt, and A. Mulyar, “Nomic embed: Training a reproducible long context text embedder,” *arXiv preprint arXiv:2402.01613*, 2024.
- [18] A. Kusupati, G. Bhatt, A. Rege, M. Wallingford, A. Sinha, V. Ramanujan, W. Howard-Snyder, K. Chen, S. Kakade, P. Jain *et al.*, “Matryoshka representation learning,” vol. 35, 2022, pp. 30 233–30 249.
- [19] C.-Y. Lin, “Rouge: A package for automatic evaluation of summaries,” in *Text summarization branches out*, 2004, pp. 74–81.
- [20] D. Van Veen, C. Van Uden, L. Blankemeier, J.-B. Delbrouck, A. Aali, C. Bluethgen, A. Pareek, M. Polacin, E. P. Reis, A. Seehofnerova *et al.*, “Clinical text summarization: adapting large language models can outperform human experts,” *Research square*, pp. rs–3, 2023.
- [21] J. White, Q. Fu, S. Hays, M. Sandborn, C. Olea, H. Gilbert, A. Elnashar, J. Spencer-Smith, and D. C. Schmidt, “A prompt pattern catalog to enhance prompt engineering with chatgpt,” *arXiv preprint arXiv:2302.11382*, 2023.
- [22] L. Jiang, C. Zhang, P. A. Scherz, and S. Goetz, “Can large language models generate high-quality patent claims?” pp. 1272–1287, 2025.
- [23] D. Guo, D. Yang, H. Zhang, J. Song, P. Wang, Q. Zhu, R. Xu, R. Zhang, S. Ma, X. Bi *et al.*, “Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning,” *arXiv preprint arXiv:2501.12948*, 2025.
- [24] A. Grattafiori, A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Vaughan *et al.*, “The llama 3 herd of models,” *arXiv preprint arXiv:2407.21783*, 2024.
- [25] A. Yang, B. Zhang, B. Hui, B. Gao, B. Yu, C. Li, D. Liu, J. Tu, J. Zhou, J. Lin *et al.*, “Qwen2.5-math technical report: Toward mathematical expert model via self-improvement,” *arXiv preprint arXiv:2409.12122*, 2024.
- [26] G. Team, T. Mesnard, C. Hardin, R. Dadashi, S. Bhupatiraju, S. Pathak, L. Sifre, M. Rivière, M. S. Kale, J. Love *et al.*, “Gemma: Open models based on gemini research and technology,” *arXiv preprint arXiv:2403.08295*, 2024.
- [27] B. Adler, N. Agarwal, A. Aithal, D. H. Anh, P. Bhattacharya, A. Brundyn, J. Casper, B. Catanzaro, S. Clay, J. Cohen *et al.*, “Nemotron-4 340b technical report,” *arXiv preprint arXiv:2406.11704*, 2024.
- [28] S. Agarwal, L. Ahmad, J. Ai, S. Altman, A. Applebaum, E. Arbus, R. K. Arora, Y. Bai, B. Baker, H. Bao *et al.*, “gpt-oss-120b & gpt-oss-20b model card,” *arXiv preprint arXiv:2508.10925*, 2025.
- [29] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, “Judging llm-as-a-judge with mt-bench and chatbot arena,” in *Advances in Neural Information Processing Systems*, A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, Eds., vol. 36. Curran Associates, Inc., 2023, pp. 46 595–46 623. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2023/file/91f18a1287b398d378ef22505bf41832-Paper-Datasets_and_Benchmarks.pdf
- [30] L. Heiler, K. Kirchsteiger, S. Hanke, and M. Bödenler, “Implementation and evaluation of an open-source chatbot for patient information leaflets,” *Future Internet*, vol. 18, no. 3, p. 139, 2026.

- [31] J. Clusmann, F. R. Kolbinger, H. S. Muti, Z. I. Carrero, J.-N. Eckardt, N. G. Laleh, C. M. L. Löffler, S.-C. Schwarzkopf, M. Unger, G. P. Veldhuizen *et al.*, “The future landscape of large language models in medicine,” *Communications medicine*, vol. 3, no. 1, p. 141, 2023.
- [32] D. D. Lee and H. S. Seung, “Learning the parts of objects by non-negative matrix factorization,” *nature*, vol. 401, no. 6755, pp. 788–791, 1999.
- [33] L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder, and F. Wei, “Text embeddings by weakly-supervised contrastive pre-training,” *arXiv preprint arXiv:2212.03533*, 2022.
- [34] V. M. D. Rivas, “Plantilla sencilla para la realización de trabajos de fin de grado en la escuela técnica superior de ingenieros de sistemas informáticos (universidad politécnica de madrid),” <https://es.overleaf.com/latex/templates/plantilla-tfg-etsisi-upm/pcnbzxbtwtgtf>, 2020.
- [35] J. S. de Dios, “Reorganización semántica no supervisada de prospectos farmacéuticos mediante modelos de lenguaje,” <https://github.com/jsaenz989/pfg-unsupervised-pil-reorganization.git>, 2026.